

ANNÉE 5 · NOCODE / LOWCODE & IA

Architecture IA

Guide des bonnes pratiques du vibecoding avec l'IA

Le manuel de référence pour construire de vrais projets avec un assistant IA

Maxime Nicole — EI KodeSaaS

Consultant IA & Développement · maxime@kodesaas.com

Sommaire

Partie 1 — L'état d'esprit : de codeur à architecte 1.1 Le nouveau rôle du développeur · 1.2 Les 5 erreurs classiques du vibecoder · 1.3 Faire confiance mais vérifier · 1.4 Petit scope, gros résultats

Partie 2 — Cadrer avant de coder (analyse & conception) 2.1 Du brief à la spec · 2.2 Domain-Driven Design (DDD) accessible · 2.3 Choisir son architecture · 2.4 Choisir sa stack · 2.5 Modéliser avant de prompter

Partie 3 — Configurer l'environnement IA 3.1 CLAUDE.md / AGENTS.md · 3.2 Les skills réutilisables · 3.3 Les serveurs MCP · 3.4 Conventions d'équipe · 3.5 Choisir ses outils

Partie 4 — Le workflow de développement piloté par IA 4.1 Le cycle Issue → Branche → Code → Review → Merge · 4.2 GitHub Issues · 4.3 Les branches Git · 4.4 Bien prompter pour coder · 4.5 La méthode SOP : le prompt comme procédure · 4.6 La Pull Request · 4.7 La code review assistée par IA · 4.8 Des commits propres

Partie 5 — Qualité & tests 5.1 Pourquoi tester quand l'IA code · 5.2 La pyramide des tests · 5.3 Le TDD avec l'IA (RED → GREEN → REFACTOR) · 5.4 Les 4 piliers d'un code reprenable

Partie 6 — Déploiement & mise en production 6.1 Conteneuriser avec Docker · 6.2 Où héberger : VPS, PaaS, Vercel · 6.3 Les briques de prod minimales · 6.4 Monitoring d'erreurs · 6.5 CI/CD avec GitHub Actions · 6.6 Les tâches de fond (Trigger.dev)

Partie 7 — Sécurité & conformité 7.1 Les réflexes de base · 7.2 L'OWASP Top 10 pour vibecoders · 7.3 L'audit de sécurité piloté par IA · 7.4 Conduire un pentest : méthode et exemple · 7.5 Le cadre légal · 7.6 RGPD & le règlement IA européen (AI Act)

Partie 8 — Choisir et gérer ses données 8.1 Relationnel vs NoSQL · 8.2 PostgreSQL, MySQL, MariaDB · 8.3 Le NoSQL : MongoDB & compagnie · 8.4 Bases managées & serverless : Neon, Supabase · 8.5 Les bases no-code : Baserow

Partie 9 — Intégrer l'IA dans son produit 9.1 Appeler un LLM depuis son code · 9.2 OpenRouter & le choix des modèles · 9.3 Le RAG : donner ses données à l'IA · 9.4 Maîtriser contexte, tokens et coûts · 9.5 Agents & orchestration · 9.6 Les garde-fous indispensables

Partie 10 — Boîte à outils & récap 10.1 Checklist de démarrage · 10.2 Tableau récap des outils · 10.3 Les anti-patterns à fuir · 10.4 Pour aller plus loin

Partie 1 — L'état d'esprit : de codeur à architecte

Vibecoder, ce n'est pas déléguer le cerveau. C'est déplacer votre effort : moins de temps à taper des lignes, plus de temps à décider quoi construire, à cadrer, à relire. L'IA écrit vite ; elle ne sait pas ce que vous voulez vraiment. Cette partie pose l'état d'esprit sans lequel tout le reste du guide ne servirait à rien : vous êtes désormais responsable du *quoi* et du *pourquoi*, l'IA prend en charge une partie du *comment*.

1.1 — Le nouveau rôle du développeur

Quand vous vibecodez, vous passez de l'exécutant à l'architecte-reviewer. L'IA produit du code plausible en quelques secondes ; votre valeur n'est plus dans la vitesse de frappe, mais dans trois choses qu'elle ne fait pas seule : décider de l'architecture, formuler des demandes précises, et juger ce qui revient. Un développeur qui « laisse l'IA coder » sans piloter obtient un patchwork qui compile mais ne tient pas : incohérences de style, doublons, décisions structurantes prises au hasard d'un prompt.

Concrètement, l'architecte fait des choix que l'IA n'a aucun moyen de deviner. Sur eRezo (notre SaaS-exemple de gestion de contacts et d'événements), personne dans un prompt ne tranchera à votre place : est-ce qu'un contact peut exister sans être rattaché à une organisation ? Est-ce qu'un événement annulé garde ses inscriptions ? Ces décisions de domaine déterminent le modèle de données et se paient très cher si on les prend après coup. L'IA, elle, comblera le vide par une convention arbitraire — souvent la plus banale de son corpus d'entraînement.

Le reviewer, c'est l'autre moitié du rôle. Vous lisez chaque diff comme si un développeur junior compétent mais sans contexte l'avait écrit : rapide, parfois brillant, parfois à côté. Votre travail est de repérer ce qui ne colle pas à *votre* projet, pas de vérifier que « ça a l'air correct ».

Astuce — Avant de lancer un prompt de code, posez-vous : « Est-ce que je saurais expliquer à voix haute la solution attendue ? » Si non, vous n'êtes pas encore en position d'architecte : cadrez d'abord (voir Partie 2). Sinon vous ne pourrez pas juger ce que l'IA vous rend.

✅ À faire	❌ À éviter
Décider l'architecture et le modèle de données avant de prompter	Découvrir l'archi de son app en lisant le code généré
Lire chaque diff avant de l'accepter	Enchaîner « accepte tout » jusqu'à ce que ça tourne
Garder en tête l'intention métier	Déléguer les décisions structurantes à un prompt vague

1.2 — Les 5 erreurs classiques du vibecoder

Cinq pièges reviennent en boucle et suffisent à faire dérailler un projet. Nommez-les pour les reconnaître à temps.

1. Le prompt-fleuve (« construis-moi l'app »). Demander une fonctionnalité entière d'un coup produit du code massif, impossible à relire sérieusement, où une erreur se cache facilement. Découpez (voir 1.4).

2. L'acceptation aveugle. Cliquer « accepter » sans lire, parce que « ça a l'air bon » et que les tests passent. Les bugs les plus coûteux passent les tests : logique métier fausse, cas limites ignorés, faille de sécurité invisible à l'exécution.

3. Le contexte amnésique. Lancer chaque prompt sans donner à l'IA les conventions, la stack, l'existant. Résultat : elle réinvente une façon de faire à chaque fichier. C'est précisément ce que règlent le `CLAUDE.md` et les conventions (Partie 3).

4. La dérive de scope. Laisser l'IA « améliorer pendant qu'elle y est » : elle renomme des variables, refactorise un module voisin, ajoute une dépendance non demandée. Chaque écart non sollicité est un risque non relu.

5. Le copier-coller sans compréhension. Intégrer du code qu'on serait incapable de réexpliquer. Le jour du bug en production, vous êtes seul face à du code que vous n'avez jamais vraiment lu — et l'IA qui l'a écrit ne s'en souvient plus.

Exercice — Sur votre dernier projet vibecodé, comptez combien de ces cinq erreurs vous reconnaissez. La plupart des débutants en cochent quatre. En cocher zéro consciemment, c'est déjà avoir changé de posture.

✅ À faire	❌ À éviter
Une tâche = un prompt = un diff relu	« Construis toute la feature X » en un coup
Fournir stack + conventions à chaque session	Prompter à froid, sans contexte projet
Refuser tout changement hors du scope demandé	Laisser l'IA refactorer ce qu'on ne lui a pas demandé

1.3 — Faire confiance mais vérifier

L'IA génère le texte le plus probable, pas le plus vrai. Deux conséquences pratiques que vous rencontrerez cette semaine.

D'abord, **l'hallucination de dépendances** : elle invente une librairie, une fonction ou une option de config qui n'existe pas, parce qu'elle « aurait dû » exister. Ensuite, **le code faux qui a l'air juste** : il compile, il passe le cas nominal, mais la logique est erronée sur les cas limites ou les hypothèses métier.

Exemple concret sur eRezo. Vous demandez de filtrer les événements à venir. L'IA vous rend :

```
// Généré par l'IA — a l'air correct, mais...
$events = $repository->findBy(['status' => 'active']);
$upcoming = array_filter($events, fn($e) => $e->getDate() > new DateTime());
```

Ça « marche » à la démo. Deux problèmes : on charge **tous** les événements actifs en mémoire avant de filtrer (catastrophe avec 50 000 lignes), et la comparaison ignore le fuseau horaire — un événement du soir peut disparaître selon l'heure du serveur. Le code passe un test naïf ; il est faux à l'échelle. Seul un reviewer qui connaît le domaine le voit.

Le réflexe de vérification tient en trois gestes rapides : **(1)** la dépendance existe-t-elle vraiment ? (vérifiez sur le registre officiel — npm, Packagist, PyPI — ou la doc, jamais sur la seule parole de l'IA) ; **(2)** est-ce que je comprends *pourquoi* ce code fonctionne, ligne par ligne ? ; **(3)** quels cas limites ne sont pas couverts (liste vide, gros volume, valeur nulle, fuseau, concurrence) ? Ces trois questions coûtent deux minutes et évitent des heures de débogage en production.

💡 **Astuce** — Face à un import ou une fonction que vous ne connaissez pas, ne demandez pas à l'IA « est-ce que ça existe ? » (elle confirmera volontiers son invention). Allez le vérifier à la source. Une hallucination ne s'auto-détecte pas.

✅ À faire	❌ À éviter
Vérifier chaque librairie sur le registre officiel	Croire l'IA sur l'existence d'un package
Tester les cas limites, pas seulement le cas nominal	Conclure « ça marche » parce que la démo passe
Exiger de soi-même de comprendre chaque ligne acceptée	Intégrer du code qu'on ne saurait pas réexpliquer

1.4 — Petit scope, gros résultats

Contre-intuitif mais vérifiable : plus vous contraignez l'IA, meilleur est le code. Un prompt géant force le modèle à prendre des dizaines de micro-décisions implicites, à tenir tout le contexte à la fois, et vous rend un bloc que personne ne peut relire honnêtement. Une tâche unique et bien bornée produit du code ciblé, testable, et surtout *relisable en une passe*.

Comparez. Le prompt large : « Ajoute la gestion des inscriptions aux événements dans eRezo. » L'IA doit inventer le modèle, l'endpoint, la validation, l'email de confirmation, la gestion des places, l'UI — et se trompera silencieusement sur au moins un de ces points. Le même travail découpé :

- « Crée l'entité `Registration` : un contact, un événement, une date d'inscription, un statut (`confirmed` / `waitlist`). »
- « Ajoute la règle : si l'événement est complet (capacité atteinte), le statut passe à `waitlist` . Écris le test d'abord. »
- « Expose un endpoint `POST /events/{id}/register` qui utilise cette logique. »

Chaque étape tient dans un diff que vous relisez en une minute, chacune est testable isolément, et si l'étape 2 est fausse vous le voyez immédiatement — pas noyée dans 400 lignes. Bonus : quand un prompt échoue, vous savez exactement lequel reprendre,

au lieu de tout jeter.

La règle simple : **une intention par prompt**. Si votre demande contient un « et » qui ajoute une responsabilité (« crée l'entité et l'endpoint et l'email »), coupez. Le découpage n'est pas une lenteur, c'est ce qui rend le résultat fiable et rejoint directement le workflow Issue → PR → Merge de la Partie 4, où chaque petite unité devient une PR relue.

Exercice — Prenez une fonctionnalité que vous vouliez demander « en un coup ». Écrivez-la sous forme de 3 à 5 sous-tâches, chacune formulée comme un prompt indépendant avec un critère de réussite clair. C'est exactement le découpage qu'attend un bon reviewer — vous.

✅ À faire	❌ À éviter
Une intention métier par prompt	Empiler les responsabilités avec des « et »
Découper en étapes testables isolément	Demander une feature entière d'un seul jet
Relire chaque petit diff avant le suivant	Enchaîner sans relire jusqu'à « ça compile »

Partie 2 — Cadrer avant de coder (analyse & conception)

Le réflexe du vibecoding, c'est de lancer un prompt « code-moi une app de gestion d'événements » et de voir ce qui sort. Ça marche pour une démo, jamais pour un produit. Un cadrage sérieux vous fait gagner des jours : l'IA produit un code cohérent seulement si elle sait *quoi* construire et *comment* c'est structuré. Cette partie vous apprend à transformer une idée floue en plan exploitable — avant la première ligne de code.

2.1 — Du brief à la spec : transformer une idée floue en spécifications claires

Une idée dans votre tête n'est pas une spec. « Je veux un outil pour gérer mes contacts et mes événements » contient dix décisions implicites que l'IA va deviner à votre place — mal. Le travail de cadrage consiste à rendre ces décisions explicites : qui utilise l'outil, quelles actions il pose, quelles règles métier s'appliquent, quels cas limites existent.

La bonne méthode : ne demandez pas à l'IA de coder, demandez-lui de **vous interviewer**. Un LLM est excellent pour poser les questions que vous n'avez pas anticipées. Vous partez d'un brief flou, il vous challenge, vous répondez, et la spec se construit par itérations.

Exemple de dialogue idée → spec :

Vous : Je veux un SaaS pour gérer des contacts pro et organiser des événements de networking. C'est encore flou. Avant d'écrire du code, pose-moi les questions nécessaires pour rédiger une spec claire. Ne code rien pour l'instant.

IA : 5 questions pour cadrer :

1. Un contact appartient à un seul utilisateur, ou est-il partagé dans une organisation ?
2. Un événement a-t-il une capacité max, une billetterie, ou juste une liste d'inscrits ?
3. Les participants à un événement sont-ils forcément des contacts existants, ou peuvent-ils s'inscrire sans compte ?
4. Faut-il un historique des interactions (dernier contact, notes) ?
5. Y a-t-il de la messagerie, ou juste des emails transactionnels ?

Vous : 1) Partagé dans une organisation. 2) Capacité max + liste d'inscrits, pas de paiement pour le MVP. 3) Inscription possible sans compte, on rattache plus tard. 4) Oui, notes + date de dernier échange. 5) Emails transactionnels seulement pour le MVP.

IA : Voici la spec du MVP :

- Entités : Organisation, Utilisateur, Contact, Événement, Inscription, Note
- Règle : un Contact appartient à une Organisation (pas à un User)
- Règle : une Inscription peut exister sans Contact rattaché (email seul)
- Règle : capacité max sur Événement → refus d'inscription si complet
- Hors périmètre MVP : paiement, messagerie temps réel

En dix minutes, vous êtes passé d'une phrase à une liste d'entités, de règles métier et d'un périmètre. C'est ça, une spec exploitable.

✓ À faire

- Demander à l'IA de vous interviewer avant de produire quoi que ce soit
- Fixer explicitement le **hors périmètre** (« pas de paiement pour le MVP »)
- Formuler les règles métier en phrases testables (« refus si complet »)

⊘ À éviter

- Lancer « code-moi l'app » et corriger après coup

- Laisser l'IA supposer les cas limites (elle choisira le plus simple, pas le vôtre)
- Empiler les fonctionnalités « tant qu'on y est »

💡 **Astuce** : sauvegardez cette spec dans un fichier `SPEC.md` à la racine du projet. Il servira de source de vérité pour tous vos prompts suivants et alimentera votre `CLAUDE.md` (voir Partie 3).

2.2 — Domain-Driven Design (DDD) accessible


Le DDD est une façon de découper un logiciel non pas par technique (« les contrôleurs », « les modèles ») mais par **métier**. L'idée centrale tient en une phrase : votre code doit parler le langage de votre domaine, pas celui de la base de données. Trois notions suffisent pour démarrer.

Ubiquitous language (langage partagé) — tout le monde, humains et IA, utilise les mêmes mots. Si le métier dit « Inscription », le code n'écrit pas `EventUserLink`. Ce vocabulaire commun élimine la moitié des malentendus. Quand vous prompterez l'IA, elle réutilisera vos termes exacts au lieu d'inventer les siens.

Bounded context (contexte délimité) — un grand SaaS se découpe en zones métier autonomes, chacune avec ses propres règles et son propre vocabulaire. Analogie : dans une entreprise, la compta et le service commercial parlent tous les deux de « client », mais n'en font pas la même chose. Ce sont deux contextes. On les sépare pour qu'une règle de facturation ne pollue pas la logique commerciale.

Entité et agrégat — une *entité* est un objet métier identifiable dans le temps (un Contact, un Événement). Un *agrégat* est un groupe d'entités qu'on manipule comme un tout, via une seule porte d'entrée appelée *racine*. Analogie : une commande et ses lignes forment un agrégat — on ne modifie jamais une ligne toute seule, on passe toujours par la commande, qui garantit la cohérence (le total reste juste).

Découpage concret d'eRezo (SaaS contacts + événements) en bounded contexts :



Ici, « Contacts » gère la vie du carnet d'adresses ; « Événements » gère les inscriptions et la capacité ; ils communiquent par un identifiant, pas en fouillant dans les tables l'un de l'autre. Résultat : quand vous demandez à l'IA de modifier la règle de capacité, elle touche un seul contexte sans risquer de casser la messagerie.

✅ À faire

- Nommer vos contextes avec des mots métier (Contacts, Événements)
- Faire passer toute modification par la racine d'agrégat
- Imposer le langage partagé à l'IA dans vos prompts

🚫 À éviter

- Un seul modèle géant `User` qui sert partout
- Des entités d'un contexte qui accèdent directement aux tables d'un autre
- Un vocabulaire différent entre la spec, la BDD et le code


💡 **Astuce** : pas besoin de DDD tactique complet (value objects, domain events...) pour un MVP. Retenez trois choses : langage partagé, contextes délimités, racines d'agrégat. C'est 80 % de la valeur pour 20 % de l'effort.

2.3 — Choisir son architecture

Pour un MVP, la question « microservices ou pas » a une réponse simple : **pas de microservices**. Ils résolvent un problème d'échelle et d'équipes multiples que vous n'avez pas encore. Ils coûtent cher en complexité — réseau, déploiement, cohérence des données, débogage réparti. Commencer par des microservices, c'est payer une assurance pour un risque qui n'existe pas.

La bonne cible : le **monolithe modulaire**. Une seule application, un seul déploiement, une seule base de données — mais découpée à l'intérieur en modules qui correspondent à vos bounded contexts. Chaque module a une frontière claire et ne parle aux autres que par des interfaces définies. Vous gardez la simplicité d'un monolithe et la propreté d'une architecture découpée. Le jour où un module doit vraiment devenir un service séparé, la frontière existe déjà : l'extraction est mécanique.

L'**architecture hexagonale** (ports & adapters) complète bien ce choix. L'idée : votre logique métier au centre ne dépend d'aucune technologie. Elle expose des *ports* (interfaces : « je sais envoyer un email », « je sais sauvegarder un contact ») et les détails techniques sont des *adapters* branchés dessus (Resend pour l'email, PostgreSQL pour la persistance). Analogie : une prise électrique murale. Votre logique métier, c'est l'appareil ; le port, c'est la prise ; l'adapter, c'est le câble. Vous changez de fournisseur d'email sans toucher au métier — juste l'adapter.



✅ À faire

- Démarrer en monolithe modulaire, un module par contexte
- Isoler les dépendances externes (email, paiement) derrière des ports
- Garder un seul déploiement tant que la charge ne l'impose pas

🚫 À éviter

- Microservices « parce que c'est moderne »
- Coller la logique métier directement dans les contrôleurs
- Appeler une librairie externe depuis le cœur métier

💡 **Astuce** : pour un MVP, l'hexagonal complet peut être surdimensionné. Appliquez-le au minimum sur ce qui change souvent de fournisseur (email, stockage de fichiers, paiement). Le reste peut rester simple.

2.4 — Choisir sa stack

Choisir sa stack sur la hype, c'est la garantie de galérer seul sur un problème que personne n'a encore documenté. Les critères qui comptent réellement sont au nombre de quatre, et aucun ne s'appelle « nouveauté ».

Maturité — une techno stable a ses bugs connus et corrigés, une API qui ne casse pas à chaque version. **Écosystème et support** — c'est décisif en vibecoding : plus une techno est présente dans les données d'entraînement, plus l'IA génère du code correct du premier coup. Symfony, Laravel, Django, Rails, React, Next.js : l'IA les maîtrise. Un framework sorti il y a six mois : elle hallucine des méthodes qui n'existent pas. **Communauté** — quand vous bloquez, une réponse Stack Overflow ou un thread GitHub existent déjà. **Coût** — hébergement, licences, montée en charge, et coût de recrutement si vous grandissez.

Concrètement, pour un SaaS type eRezo, un choix raisonnable : Symfony ou Laravel (PHP) côté back, PostgreSQL en base, un front server-rendered ou React si l'interactivité l'exige. Ce sont des technos matures, massivement documentées, que l'IA connaît par cœur. Vous avancez trois fois plus vite qu'avec une stack exotique où chaque prompt exige une vérification manuelle.

✓ À faire

- Privilégier les technos que l'IA maîtrise (test : demandez-lui un CRUD, jugez la qualité)
- Choisir du mature et documenté pour un projet qui doit durer
- Vérifier le coût d'hébergement réel avant de vous engager

⊘ À éviter

- Adopter un framework « tendance » de moins d'un an pour un MVP
- Empiler cinq technos que vous ne maîtrisez pas
- Ignorer que l'IA code mieux sur les stacks populaires

💡 **Astuce** : avant de figer votre choix, demandez à l'IA de générer une petite fonctionnalité représentative dans deux stacks candidates. La différence de qualité et de fluidité vous donne la réponse en dix minutes.

2.5 — Modéliser avant de prompter

Dernière étape avant de coder : faire produire à l'IA le **modèle**, pas le code. Un schéma de données, une arborescence de dossiers, la liste des entités et de leurs relations. C'est le squelette. Une fois validé, chaque prompt de code s'appuie dessus et reste cohérent. Sauter cette étape, c'est laisser l'IA improviser un schéma différent à chaque fichier généré.

Commencez par le schéma de données, car c'est lui qui contraint tout le reste. Prompt type :

```
À partir de la spec dans SPEC.md, propose le schéma de données du MVP
sous forme de tables (nom, colonnes, types, clés étrangères, contraintes).
Respecte les bounded contexts : Contacts, Événements, Comptes.
Ne génère PAS de code, seulement le modèle. Signale les décisions
ambiguës plutôt que de trancher seul.
```

Sortie attendue, à relire ligne à ligne :

```
[Comptes]
organisation (id, nom, created_at)
utilisateur (id, organisation_id FK, email UNIQUE, role)

[Contacts]
contact      (id, organisation_id FK, nom, email, entreprise,
              dernier_echange_at)
note         (id, contact_id FK, auteur_id FK, contenu, created_at)

[Événements]
evenement    (id, organisation_id FK, titre, date, capacite_max)
inscription  (id, evenement_id FK, contact_id FK NULLABLE,
              email, statut)
              -- contact_id NULLABLE : inscription possible sans compte
```

C'est ici que vous validez les règles métier avant qu'elles ne se figent dans le code : le `contact_id NULLABLE` reflète la règle « inscription sans compte » de la spec. Une erreur à ce stade coûte une phrase à corriger ; la même erreur après trois jours de code coûte une refonte.

Faites ensuite produire l'arborescence, alignée sur les contextes :

```
src/
  Comptes/      (Utilisateur, Organisation, auth)
```

Contacts/	(Contact, Note, Interaction)
Evenements/	(Evenement, Inscription, règle capacité)
Shared/	(types communs, utilitaires)

✅ À faire

- Valider schéma + arborescence avant le premier fichier de code
- Relire chaque table et chaque relation comme un contrat
- Aligner la structure de dossiers sur les bounded contexts

🚫 À éviter

- Demander le code et le modèle dans le même prompt
- Accepter un schéma sans vérifier les clés étrangères et les contraintes
- Laisser l'IA « ajuster » le modèle en cours de route sans revalider

💡 **Astuce** : gardez le schéma validé dans `SPEC.md` ou un `MODEL.md`. Injectez-le en contexte à chaque session de code : l'IA s'y conforme et cesse d'improviser des tables au fil des fichiers. C'est le pont direct vers la Partie 4.

Partie 3 — Configurer l'environnement IA

Un assistant IA ne « connaît » pas votre projet. À chaque nouvelle session, il repart d'une page blanche : il ne sait pas quel framework vous utilisez, comment vous nommez vos fichiers, ni quelles commandes lancent vos tests. Configurer l'environnement, c'est donner à l'IA un contexte stable pour qu'elle produise du code cohérent avec le vôtre — sans que vous ayez à tout réexpliquer à chaque fois. Cette partie couvre les quatre briques qui font la différence entre un assistant qui devine et un assistant qui sait : le fichier de contexte, les skills, les serveurs MCP, et les conventions d'équipe. Elle se termine sur le choix des outils.

3.1 — CLAUDE.md / AGENTS.md : le fichier de contexte

Le fichier de contexte (appelé `CLAUDE.md` chez Claude Code, `AGENTS.md` dans d'autres outils, `.cursorrules` chez Cursor) est un fichier markdown placé à la racine du projet. L'IA le lit automatiquement au démarrage de chaque session. C'est votre levier le plus rentable : cinq minutes d'écriture évitent des centaines de rappels du type « non, on utilise pnpm, pas npm » ou « mets les composants dans `src/components`, pas ailleurs ».

Le principe : y mettre ce qui est **stable et transversal** au projet — la stack, les conventions, les commandes, les pièges connus. Pas le détail d'une feature en cours (ça, ça va dans le prompt du moment). Un bon fichier de contexte tient sur une ou deux pages. Trop long, il se dilue et l'IA en ignore des parties ; trop court, il ne sert à rien.

Voici un squelette réaliste, commenté, pour une petite app web :

Contexte projet

TaskFlow — application de gestion de tâches pour équipes.
Utilisateurs : PME, 5 à 50 personnes. MVP en cours, pas encore en production.
Objectif de la phase actuelle : livrer l'authentification + le CRUD tâches.

Stack technique

- Frontend : React 18 + TypeScript + Vite
- Styles : Tailwind CSS v4 (pas de CSS modules, pas de styled-components)
- Backend : Node.js + Fastify
- Base de données : PostgreSQL via Prisma
- Tests : Vitest (unitaires) + Playwright (E2E)
- Gestionnaire de paquets : pnpm (JAMAIS npm ni yarn)

Conventions de code

- Composants React : un fichier par composant, PascalCase (`TaskCard.tsx`)
- Hooks perso : préfixe `use`, dans `src/hooks/`
- Pas de `any` en TypeScript — typer explicitement
- Fonctions asynchrones : gérer les erreurs avec `try/catch`, jamais de promesse non gérée
- Commits : format Conventional Commits (`feat:`, `fix:`, `chore:`)

Commandes utiles

- `pnpm dev` — lance le serveur de dev
- `pnpm test` — lance les tests unitaires
- `pnpm test:e2e` — lance Playwright
- `pnpm db:migrate` — applique les migrations Prisma
- `pnpm lint` — vérifie le code (à lancer avant chaque commit)

À faire / À éviter

- ☒ Toujours écrire un test pour toute nouvelle fonction métier

-  Réutiliser les composants existants de ``src/components/ui/``
-  Ne jamais commiter de secret / clé API (utiliser ``.env``, déjà gitignoré)
-  Ne pas modifier ``prisma/schema.prisma`` sans créer une migration
-  Ne pas installer de nouvelle dépendance sans me demander avant

À faire / À éviter

-  Mettre à jour le fichier quand une convention change (c'est un document vivant).
-  Être précis et impératif : « utiliser `pnpm` » vaut mieux que « on préfère `pnpm` ».
-  Éviter le roman : l'IA lit mieux 40 lignes nettes que 400 lignes floues.
-  Ne pas y copier toute votre documentation — un lien vers `docs/` suffit.

 **Astuce** : quand l'IA fait une erreur récurrente (elle oublie de lancer le lint, elle réinvente un composant qui existe), ne la corrigez pas seulement dans le chat — ajoutez une ligne dans le fichier de contexte. C'est ainsi qu'il s'affine au fil du temps.

3.2 — Les skills réutilisables

Une **skill** est une procédure encapsulée que l'IA peut déclencher à la demande, sans que vous ayez à réexpliquer les étapes. Concrètement, c'est un petit dossier contenant un fichier markdown qui décrit *quand* utiliser la skill et *comment* exécuter la tâche. Là où le fichier de contexte décrit le projet en permanence, la skill décrit un savoir-faire ponctuel qu'on sort de sa boîte au bon moment. C'est la différence entre « voici la maison » et « voici la recette pour faire une migration proprement ».

L'intérêt pour qui vibecode : vous transformez vos procédures répétitives en actions fiables et reproductibles. Au lieu de réécrire à chaque fois « pour créer un endpoint, ajoute la route, le contrôleur, le test, et mets à jour la doc OpenAPI », vous l'écrivez une fois dans une skill, et vous invoquez « crée l'endpoint POST /tasks » quand vous en avez besoin.

Quelques exemples de skills utiles pour un projet type :

- **create-endpoint** — crée une route API complète : handler, validation des entrées, test, entrée dans la doc.
- **add-migration** — génère une migration de base de données en respectant la convention de nommage et vérifie qu'elle est réversible.
- **review-pr** — relit un diff selon une check-list maison (sécurité, tests, nommage) avant ouverture de PR.
- **deploy-preview** — enchaîne build, tests et déploiement d'un environnement de preview.
- **write-changelog** — génère une entrée de changelog à partir des derniers commits.

À faire / À éviter

-  Créer une skill dès qu'une procédure revient pour la 3^e fois.
-  Écrire une description de déclenchement claire (« utiliser quand on ajoute une route API ») — c'est ce qui permet à l'IA de savoir quand la sortir.
-  Ne pas coder une skill pour une action unique : le prompt direct suffit.
-  Ne pas y cacher de logique critique non relue — une skill exécute, elle ne réfléchit pas à votre place.

 **Astuce** : commencez par observer ce que vous répétez sur une semaine. Les trois demandes que vous formulez le plus souvent sont vos trois premières skills.

3.3 — Les serveurs MCP (Model Context Protocol)

Par défaut, l'IA ne peut ni lire votre base de données, ni ouvrir une issue GitHub, ni consulter la documentation à jour d'une librairie. Le **MCP (Model Context Protocol)** est un standard qui connecte l'assistant à des outils réels. Imaginez-le comme une prise universelle : chaque **serveur MCP** est un adaptateur qui expose les fonctions d'un service (GitHub, PostgreSQL, un navigateur, une base de docs) sous une forme que l'IA sait appeler. Une fois branché, l'assistant ne devine plus — il va chercher la vraie information et agit sur les vrais systèmes.

Le gain est double. D'abord, la **justesse** : au lieu d'inventer le schéma de votre table `users`, l'IA interroge la base et lit les colonnes réelles. Ensuite, l'**action** : elle peut créer une pull request, lancer une requête, ou naviguer sur une page pour vérifier un rendu. Quelques serveurs MCP courants et leur usage concret :

- **GitHub** — « ouvre une issue pour ce bug », « liste les PR en attente de review », « lis le contenu de l'issue #42 ».
- **Base de données (PostgreSQL, etc.)** — « montre-moi le schéma de la table commandes », « combien d'utilisateurs inscrits ce mois-ci ? » (idéalement en lecture seule).
- **Context7** — récupère la documentation à jour d'une librairie ou d'un framework, au lieu de s'appuyer sur des versions périmées mémorisées par le modèle. « Comment on configure les routes dans la dernière version de Fastify ? » renvoie la doc réelle, pas une supposition.
- **Navigateur (Playwright, etc.)** — « ouvre la page d'accueil et dis-moi si le formulaire s'affiche », utile pour tester un rendu ou reproduire un bug visuel.

✓ À faire / ⚠ À éviter

- ✓ Donner des accès **en lecture seule** quand c'est possible, surtout pour les bases de données.
- ✓ Vérifier ce qu'un serveur MCP peut faire avant de le brancher — certains agissent sur des systèmes de production.
- ⚠ Ne jamais connecter un MCP avec des droits d'écriture à une base de prod « pour tester ».
- ⚠ Ne pas coller vos tokens d'accès dans un fichier versionné — ils vont dans la config locale ou les variables d'environnement.

💡 **Astuce** : le serveur MCP de documentation (type Context7) est celui qui évite le plus d'erreurs quand vous vibecodez avec des librairies récentes. Le modèle a une date de coupure de connaissances ; la doc live, non.

3.4 — Conventions d'équipe

Quand plusieurs personnes vibecodent sur le même dépôt, le risque n'est pas la vitesse — c'est l'incohérence. Chacun a « son » assistant, avec ses habitudes, et le code se met à diverger : deux façons de nommer les fichiers, deux styles de gestion d'erreur, deux structures de dossiers. La parade est simple : **le contexte de l'IA doit être partagé, versionné, et unique.**

Concrètement, le fichier `CLAUDE.md` (ou `AGENTS.md`) est **commité dans le dépôt**, pas gardé en local. Tout le monde travaille donc avec les mêmes règles, et quand quelqu'un fait évoluer une convention, il modifie le fichier dans une PR que l'équipe relit. Les conventions cessent d'être des habitudes tacites pour devenir un document explicite que l'IA applique à tous de la même façon.

Les points à figer collectivement, dans le fichier de contexte partagé ou un `CONVENTIONS.md` lié :

- **Nommage** — fichiers, variables, branches Git (`feat/nom-court`), messages de commit.
- **Structure des dossiers** — où vont les composants, les services, les tests.
- **Gestion des erreurs et des logs** — un seul pattern, pas trois.
- **Processus** — lint avant commit, tests obligatoires, review avant merge.

✓ À faire / ⚠ À éviter

- ✓ Versionner le fichier de contexte et le traiter comme du code (relu en PR).
- ✓ Ajouter les skills partagées au dépôt pour que toute l'équipe en profite.
- ⚠ Ne pas laisser chacun bricoler son propre fichier local non partagé — c'est la porte ouverte à la divergence.
- ⚠ Ne pas changer une convention en solo : proposez-la en PR, discutez-la, puis appliquez.

💡 **Astuce** : gardez une réserve de préférences strictement personnelles (raccourcis, verbosité, langue des explications) dans un fichier de config **local et non versionné**. Le fichier partagé décrit le projet ; le fichier local décrit votre confort. Ne mélangez pas les deux.

3.5 — Choisir ses outils

Plusieurs outils permettent de vibecoder, et ils se répartissent surtout selon un axe : **terminal-first** ou **éditeur-first**. Aucun n'est objectivement meilleur — le bon choix dépend de votre façon de travailler et de la nature de la tâche.

- **Claude Code** — assistant en ligne de commande (terminal). Il vit dans votre terminal, lit et modifie les fichiers du projet, lance des commandes, orchestre des tâches longues et multi-étapes. Adapté si vous êtes à l'aise avec la ligne de

commande, si vous automatisez beaucoup, ou si vous voulez que l'IA enchaîne des actions (tests, git, déploiement) sans quitter le flux.

- **Cursor** — éditeur de code (un fork de VS Code) avec l'IA intégrée dans l'interface. Vous gardez l'expérience visuelle classique : arborescence de fichiers, onglets, complétion en ligne, chat latéral qui voit le fichier ouvert. Adapté si vous préférez voir votre code à l'écran, éditer visuellement, et garder l'IA « à côté » plutôt qu'aux commandes.
- **Les extensions IDE** (type assistants intégrés à VS Code, JetBrains) — s'ajoutent à un éditeur existant, surtout pour de la complétion et de l'aide contextuelle ponctuelle. Moins orientées tâche autonome, plus « autocomplétion intelligente ».

Les critères qui comptent vraiment au moment de choisir : votre confort avec le terminal, le besoin d'automatisation (plus il est fort, plus le terminal-first brille), l'intégration avec vos outils (MCP, CI/CD), et le prix. Beaucoup de développeurs finissent par en combiner deux : un éditeur-first pour le travail visuel au quotidien, un terminal-first pour les tâches lourdes et automatisées. Les fichiers de contexte, les skills et les MCP décrits plus haut fonctionnent d'ailleurs, sous une forme ou une autre, dans la plupart de ces outils — l'investissement que vous faites dans la configuration n'est donc pas perdu si vous changez.

✅ À faire / ❌ À éviter

- ✅ *Tester au moins un outil terminal-first et un éditeur-first avant de vous fixer.*
- ✅ *Choisir selon vos tâches réelles, pas selon la hype.*
- ❌ *Ne pas vous enfermer dans un seul outil par principe — ils sont complémentaires.*
- ❌ *Ne pas négliger la config (contexte, skills, MCP) sous prétexte que « l'outil est plus malin » : c'est la config qui fait la qualité, pas la marque.*

💡 **Astuce** : jugez un outil sur une vraie tâche de votre projet, pas sur une démo. Demandez-lui d'ajouter une petite feature de bout en bout et regardez comment il gère votre contexte, vos conventions et vos erreurs. C'est là que les différences apparaissent.


Partie 4 — Le workflow de développement piloté par IA

Coder avec l'IA sans méthode, c'est empiler des correctifs jusqu'à ce que plus rien ne fonctionne. La méthode change tout : elle transforme l'IA en coéquipière disciplinée plutôt qu'en générateur de dette technique. Cette partie décrit le workflow que les équipes pro utilisent depuis des années — **issue**, **branche**, **code**, **review**, **merge** — et montre comment l'appliquer quand c'est l'IA qui tient le clavier. L'idée directrice : petites unités de travail, isolées, tracées, relues. Vous restez le pilote ; l'IA exécute, vous validez.

4.1 — Le cycle Issue → Branche → Code → Review → Merge

Ce cycle est la colonne vertébrale de tout projet sérieux. Chaque évolution part d'une **issue** (une tâche décrite noir sur blanc), part sur sa propre **branche** (un espace isolé), reçoit du **code**, passe par une **review** (relecture humaine et IA), puis fusionne (**merge**) dans la branche principale. Rien ne rentre dans `main` sans être passé par cette boucle. C'est ce qui vous permet de savoir, six mois plus tard, pourquoi telle ligne existe et qui l'a validée.

Avec l'IA, le cycle ne change pas — sa granularité, si. L'IA va vite, donc la tentation est de tout lui faire produire d'un bloc. C'est l'erreur. Vous découpez le travail en tâches assez petites pour être relues d'un coup d'œil, et vous faites tourner la boucle une tâche à la fois. Une issue = une branche = une pull request = un sujet. L'IA vous aide à chaque étape : rédiger l'issue, écrire le code, décrire la PR, auditer avant de proposer.



Astuce : si une tâche vous paraît trop grosse pour tenir dans une seule PR relisible (disons > 300 lignes modifiées), c'est le signal de la couper en deux issues. Demandez à l'IA : « Découpe cette fonctionnalité en 3 tâches indépendantes livrables séparément. »

4.2 — GitHub Issues : découper le travail en tâches

Une issue, c'est une unité de travail écrite : un titre, un contexte, un résultat attendu. Elle sert à deux choses. D'abord à *penser* avant de coder — écrire ce qu'on veut oblige à le clarifier. Ensuite à *piloter l'IA* : une bonne issue est un brief prêt à l'emploi que vous collez à l'assistant. Le principe : une issue = une tâche que l'IA peut traiter d'un seul tenant. Pas « refais l'authentification », mais « ajoute la réinitialisation de mot de passe par email ».

L'IA excelle à transformer une intention floue en issue structurée. Donnez-lui votre idée en une phrase et demandez le formatage complet : contexte, critères d'acceptation, périmètre. Vous relisez, vous ajustez, vous créez l'issue. En ligne de commande avec GitHub CLI :

```
gh issue create --title "Ajouter la réinitialisation de mot de passe par email" \
  --body "$(cat issue.md)"
```

Exemple d'issue bien écrite :

Contexte

Les utilisateurs qui oublient leur mot de passe n'ont aucun moyen de le récupérer. Ils doivent contacter le support, ce qui génère des tickets.

Objectif

Permettre à un utilisateur de réinitialiser son mot de passe via un lien

envoyé par email.

Critères d'acceptation

- [] Un formulaire "Mot de passe oublié" demande l'email
- [] Un email contenant un lien à usage unique (valable 1h) est envoyé
- [] Le lien mène à un formulaire de nouveau mot de passe
- [] Le lien expiré ou déjà utilisé affiche une erreur claire
- [] Aucune info ne fuit si l'email n'existe pas (message générique)

Hors périmètre

- Pas de 2FA dans cette issue (fera l'objet d'une issue séparée)

Notes techniques

- Réutiliser le service d'envoi d'emails existant (src/mailer)
- Token stocké hashé en base, pas en clair

✅ À faire / ❌ À éviter

- ✅ Une issue = un sujet livrable et vérifiable seul
- ✅ Des critères d'acceptation sous forme de cases à cocher
- ✅ Préciser le **hors périmètre** — c'est ce qui empêche l'IA de déborder
- ❌ Éviter les issues fourre-tout (« améliorer le site »)
- ❌ Éviter les issues sans critère de « terminé » vérifiable

4.3 — Les branches Git : isoler chaque fonctionnalité

Une branche, c'est une copie de travail parallèle du projet. Vous y faites vos modifications sans toucher à la version stable (`main`). Tant que la branche n'est pas fusionnée, `main` reste intacte et déployable. C'est le filet de sécurité fondamental : si l'IA part dans le mur sur une branche, vous la supprimez et `main` n'a jamais bougé. Une fonctionnalité = une branche.

Le nommage compte : préfixez par le type et rappelez le sujet, par exemple `feat/reset-password` ou `fix/login-error` . On lit ainsi l'intention sans ouvrir le code. Voici les commandes de base, expliquées pour non-experts :

```
# Récupérer le projet sur sa machine (une seule fois)
git clone https://github.com/kodesaas/mon-projet.git

# Créer une nouvelle branche ET s'y placer
git checkout -b feat/reset-password

# Voir ce qu'on a modifié
git status

# Sélectionner les fichiers à enregistrer (le "." = tout)
git add .

# Enregistrer un instantané avec un message
git commit -m "feat: ajoute le formulaire mot de passe oublié"

# Envoyer sa branche sur GitHub
git push -u origin feat/reset-password

# Récupérer les dernières modifs des autres depuis GitHub
git pull
```


Le trio à retenir : `add` (je choisis ce que j'enregistre) → `commit` (j'enregistre localement, avec un message) → `push` (j'envoie sur GitHub). Le `commit` reste sur votre machine tant que vous ne l'avez pas `push`.

💡 **Astuce** : avant de démarrer une nouvelle branche, revenez sur `main` et mettez-la à jour, sinon vous partez d'une base périmée.

```
git checkout main
git pull
git checkout -b feat/nouvelle-fonctionnalite
```

✅ À faire / ❌ À éviter

- ✅ Une branche par fonctionnalité, nommée clairement
- ✅ Partir d'une `main` à jour
- ❌ Ne jamais coder directement sur `main`
- ❌ Éviter les branches qui vivent des semaines (elles divergent et deviennent l'enfer à fusionner)

4.4 — Bien prompter pour coder

Le prompt est votre principal levier de qualité. Un bon prompt donne trois choses : le **contexte** (où on est, quelle stack, quels fichiers concernés), le **périmètre exact** (ce qu'on veut, et surtout ce qu'on ne veut pas), et un **critère de réussite** (comment on saura que c'est bon). Un mauvais prompt lâche une intention vague et laisse l'IA combler les trous à votre place — souvent mal.

Refusez le « tout d'un coup ». Demander « code-moi l'appli complète » produit une masse impossible à relire, avec des choix silencieux que vous n'avez pas validés. Procédez par itérations : une brique, vous relisez, vous corrigez le tir, brique suivante. L'IA garde le contexte de la conversation, profitez-en pour affiner.

❌ Mauvais prompt :

« Fais-moi un système de réinitialisation de mot de passe. »

Trop vague : l'IA invente la stack, le stockage du token, la durée de validité, l'UX. Vous héritez de décisions que vous n'avez pas prises.

✅ Bon prompt :

« Contexte : app Node/Express, PostgreSQL, service d'email existant dans `src/mailler/`. Je veux implémenter **uniquement** la génération et l'envoi du lien de réinitialisation (issue #42). Le token doit être aléatoire, stocké **hashé** en base, valable 1h. N'implémente pas encore le formulaire de nouveau mot de passe, on le fera après. Montre-moi d'abord le plan en 3-4 étapes avant d'écrire le code, que je valide. »

Ce prompt cadre la stack, isole une seule étape, impose une contrainte de sécurité, exclut le reste, et demande un plan avant le code.

💡 **Astuce** : ajoutez « avant d'écrire le code, liste-moi les hypothèses que tu fais ». Vous verrez immédiatement les choix implicites de l'IA et pourrez les corriger avant qu'ils ne soient dans le code.

4.5 — La méthode SOP : le prompt comme procédure

Le prompting « au fil de l'eau » de la section précédente suffit pour une demande ponctuelle. Mais dès que vous réutilisez un prompt — un générateur de rapports, un assistant qui doit produire **toujours la même structure**, une étape dans un workflow automatisé —, la phrase jetée ne tient plus : la sortie varie à chaque exécution. La méthode **SOP** (*Standard Operating Procedure*, procédure opératoire standard) traite le prompt comme un document d'entreprise : des **sections fixes** qui ne laissent rien au hasard. Résultat : un prompt réutilisable qui produit la même qualité à chaque passage.

Un prompt SOP s'organise en six sections, dans cet ordre :

1. **Rôle** — qui est l'IA (expertise, posture). Fixe le registre. « Tu es un rédacteur technique expert spécialisé dans les comptes-rendus de veille concis et actionnables. »

2. **Objectif** — ce qu'elle doit accomplir, et *pourquoi*. Le résultat visé, pas la méthode.
3. **Contexte** — la situation, le destinataire, les contraintes. C'est ici qu'on pose les exigences non négociables (« *le contenu doit être dense en valeur mais aéré en présentation* »).
4. **Format de sortie** — la structure **exacte** attendue, sous forme de gabarit avec des espaces réservés [...] . C'est la section la plus puissante : vous montrez le moule, l'IA le remplit. Une sortie qu'on exploite ensuite par code (JSON) se décrit ici précisément.
5. **Données d'entrée attendues** — la forme des données que l'IA recevra (souvent un schéma JSON). Supprime l'ambiguïté sur ce à partir de quoi elle travaille.
6. **Instructions / Règles** — les règles impératives, hiérarchisées par priorité (**ABSOLUMENT CRITIQUE** , **IMPORTANT**), le ton, et surtout la **gestion des cas particuliers** (données manquantes, volume inhabituel, liens cassés...).

Pourquoi ça marche : chaque zone d'incertitude laissée à l'IA est une zone de dérive. Le Rôle verrouille le ton, le Format de sortie verrouille la structure, les Règles verrouillent les cas limites. On passe d'un résultat « à peu près » à un résultat reproductible — condition indispensable pour brancher un prompt dans une automatisation ou derrière une fonctionnalité produit (Partie 9).

Squelette minimal d'un prompt SOP :

```
# Rôle
Tu es [expertise + spécialité précise].

# Objectif
[Ce qu'il faut produire] afin de [bénéfice / pourquoi].

# Contexte
[Destinataire, situation, contraintes]. **[Exigence critique en gras.]**

# Format de Sortie
## [Titre de section avec emoji]
[Gabarit exact avec des espaces réservés [comme ceci]]
---
## [Section suivante]
[...]

# Données d'Entrée Attendues
```json
{ "champ": "type", "...": "..." }
```

## Instructions — Règles de Rédaction

**ABSOLUMENT CRITIQUE** : [règle non négociable] **IMPORTANT** : [règle forte] Gestion des cas particuliers : [donnée manquante → ...], [volume élevé → ...]

```
> ✅ **À faire** / ❌ **À éviter**
> - ✅ Réserver la SOP aux prompts **réutilisables ou complexes** (générateurs, assistants, étapes de workflow).
> - ✅ Détailler le **format de sortie** : c'est lui qui garantit une structure constante.
> - ✅ Hiérarchiser les règles (`CRITIQUE` vs `IMPORTANT`) et couvrir les cas limites.
> - ❌ Sortir l'artillerie SOP pour une demande unique et jetable – les principes de 4.4 suffisent.
> - ❌ Oublier de décrire les **données d'entrée** : sans ça, l'IA improvise leur forme.

> 💡 **Astuce** : une bonne SOP se **versionne** dans le dépôt (au même titre qu'un skill, Partie 3.2). Vous l'améliorez à chaque défaut constaté – un cas limite mal géré devient une nouvelle ligne dans les Règles. Votre prompt gagne en fiabilité à chaque itération, comme du code.
```

### ### 4.6 – La Pull Request

La pull request (PR) est la demande de fusion de votre branche dans `main`. C'est le point de contrôle : rien ne rejoint la branche principale sans passer par là. Une PR se relit, se commente, se valide ou se refuse. Elle porte une **description** qui explique le *\*quoi\** et le *\*pourquoi\** – pas le *\*comment\**, le code s'en charge. Une bonne description fait gagner un temps fou au relecteur, qu'il soit humain ou IA.

Ouvrez la PR une fois la branche poussée. Avec GitHub CLI :

```
```bash
gh pr create --title "feat: réinitialisation de mot de passe par email" \
  --body "$(cat pr.md)" --base main
```

Exemple de description de PR type :

Ce que fait cette PR

Ajoute la réinitialisation de mot de passe par email (closes #42).

Pourquoi

Les utilisateurs bloqués contactaient le support. Cette PR leur donne un parcours autonome.

Comment tester

1. Aller sur /forgot-password, saisir un email existant
2. Vérifier la réception du lien (Mailtrap en local)
3. Suivre le lien → définir un nouveau mot de passe → se connecter
4. Vérifier qu'un lien réutilisé affiche une erreur

Points d'attention pour la review

- Le token est stocké hashé (SHA-256) – voir src/auth/token.js
- Message générique si l'email n'existe pas (anti-énumération)

Hors périmètre

- Rate limiting sur le formulaire (issue #45 à suivre)

Faites relire par un humain **et** par l'IA. L'humain juge la pertinence produit et les choix structurants ; l'IA passe le code au peigne fin (sécurité, cas limites, cohérence). Les deux sont complémentaires — voir 4.7.

✅ À faire / ❌ À éviter

- ✅ Lier la PR à son issue (closes #42)
- ✅ Expliquer comment tester et où regarder
- ✅ Garder la PR petite et mono-sujet
- ❌ Éviter la PR géante mélangeant 5 fonctionnalités — impossible à relire sérieusement
- ❌ Ne pas merger sa propre PR sans qu'aucun œil, humain ou IA, ne l'ait relue

4.7 — La code review assistée par IA

Avant même de solliciter un humain, faites auditer votre code par l'IA. C'est votre premier filet : elle repère en secondes des classes d'erreurs qu'on laisse facilement passer quand on a la tête dans le guidon. L'objectif n'est pas de remplacer la relecture humaine, mais de lui présenter un code déjà dégrossi, pour qu'elle se concentre sur ce qui compte vraiment — les choix produit et d'architecture.

La clé est de demander des vérifications **précises**, pas un vague « c'est bon ? ». Donnez-lui le diff (`git diff main`) et une liste de points à contrôler. Voici ce qu'il faut systématiquement lui faire vérifier :

- **Sécurité** : injections, secrets en dur, données sensibles loguées, validation des entrées, contrôle des droits.
- **Cas limites** : valeurs nulles, listes vides, entrées inattendues, erreurs réseau non gérées.
- **Fuites de périmètre** : la PR fait-elle plus que ce que l'issue demandait ?
- **Cohérence** : le code suit-il les conventions du projet (nommage, structure, gestion d'erreurs) ?
- **Lisibilité et duplication** : du code copié-collé qui devrait être factorisé.

Exemple de prompt de revue :

« Voici le diff de ma branche (`git diff main`). Fais une revue critique orientée **sécurité et cas limites**. Pour chaque problème : le fichier, la ligne, pourquoi c'est un risque, et le correctif suggéré. Ne reformule pas ce qui va bien, va droit aux problèmes. Classe-les par gravité. »

Puis, point important : **ne suivez pas aveuglément** les retours de l'IA. Elle se trompe aussi, invente parfois des problèmes ou propose des correctifs inadaptés à votre contexte. Lisez chaque remarque, comprenez-la, tranchez. C'est vous qui signez le code.

💡 **Astuce** : demandez à l'IA de classer les remarques en « bloquant / à corriger / suggestion ». Vous traitez les bloquants avant de proposer la PR, et vous décidez du reste en connaissance de cause.

4.8 — Des commits propres

Un commit, c'est un instantané enregistré de votre travail, accompagné d'un message. L'historique des commits est la mémoire du projet : bien tenu, il raconte *pourquoi* le code a évolué et permet de revenir en arrière chirurgicalement. Mal tenu (`commit` , `fix` , encore un `fix` , ça marche enfin), il ne sert à rien. Deux règles : des commits **petits** (une idée par commit) et des messages **clairs**.

La convention la plus répandue est **Conventional Commits** : un préfixe de type, puis une description courte à l'impératif. Les types courants :

- `feat`: nouvelle fonctionnalité
- `fix`: correction de bug
- `refactor`: réorganisation sans changement de comportement
- `docs`: documentation
- `test`: ajout ou modification de tests
- `chore`: tâches annexes (dépendances, config)

Exemples de bons messages :

```
feat: ajoute la génération du token de réinitialisation
fix: corrige l'expiration du lien mot de passe (fuseau horaire)
refactor: extrait la logique d'envoi d'email dans un service
test: couvre le cas du lien déjà utilisé
```

Un petit commit ciblé se relit et s'annule facilement. Si vous devez écrire « et » dans votre message (« ajoute X **et** corrige Y »), c'est souvent deux commits. L'IA peut rédiger le message à partir de vos changements — c'est un usage parfait :

```
git add .
# Demandez à l'IA : "Regarde `git diff --staged` et propose un message
# de commit en Conventional Commits, une ligne."
git commit -m "feat: valide l'email avant l'envoi du lien de reset"
```

✅ À faire / ❌ À éviter

- ✅ Un commit = une intention cohérente
- ✅ Un message qui dit quoi et, si utile, pourquoi

-  Commiter souvent, par petites étapes
-  Éviter les commits fourre-tout de 40 fichiers sans lien
-  Éviter les messages vides de sens (`update` , `wip` , `fix2`)

💡 **Astuce** : un historique propre n'est pas de la coquetterie. Le jour où un bug apparaît, la commande `git bisect` retrouve le commit fautif automatiquement — mais seulement si chaque commit est petit et cohérent. Vos commits d'aujourd'hui sont l'outil de débogage de demain.

Partie 5 — Qualité & tests

Quand vous codez avec une IA, vous produisez dix fois plus de code qu'avant. Le problème, c'est que vous produisez aussi dix fois plus de bugs potentiels. Cette partie vous montre comment transformer les tests en filet de sécurité qui vous permet d'aller vite sans casser ce qui marche déjà.

5.1 — Pourquoi tester quand l'IA code

L'IA est une machine à générer du code plausible. « Plausible » ne veut pas dire « correct ». Elle produit en trois secondes une fonction qui *ressemble* exactement à ce que vous vouliez : bonne syntaxe, bons noms de variables, structure propre. Mais elle a mal géré le cas où le tableau est vide, elle a inversé deux conditions, ou elle a inventé une méthode qui n'existe pas dans votre librairie. Visuellement, le code est irréprochable. À l'exécution, il plante ou renvoie un résultat faux.

C'est là que le test devient votre garde-fou. Quand vous codez « au feeling » avec l'IA, vous n'avez aucune preuve que ce qu'elle vient d'écrire fonctionne. Vous *supposez* que ça marche parce que ça a l'air bien. Un test, lui, ne suppose rien : il exécute le code avec des entrées connues et vérifie que la sortie est bien celle attendue. C'est la différence entre « je pense que ça marche » et « j'ai la preuve que ça marche ».

Le piège classique du vibecoding, c'est le cycle infernal : vous demandez une fonctionnalité, l'IA la code, vous demandez une modification, l'IA casse la fonctionnalité précédente sans que vous le voyiez. Sans tests, vous ne vous en rendez compte que trois jours plus tard, en production, quand un utilisateur vous écrit. Avec une suite de tests, la régression est détectée en deux secondes, à la seconde où elle est introduite.

 **Astuce** Retournez le problème à votre avantage : demandez à l'IA d'écrire les tests **en même temps** que le code, mais relisez-les vous-même. Un test généré par la même IA qui a écrit le bug peut valider... le bug. Le test est une intention humaine : c'est vous qui décidez ce qui est « correct ».

À faire

- Écrire un test dès qu'une fonction contient de la logique (calcul, condition, transformation).
- Faire tourner la suite complète avant chaque commit.
- Traiter un test qui échoue comme un signal, pas comme une contrainte.

À éviter

- Valider une fonctionnalité juste parce que « l'écran s'affiche bien ».
- Laisser l'IA écrire ET valider seule son propre code sans relecture.
- Reporter les tests à « plus tard » (plus tard = jamais).

5.2 — La pyramide des tests : unitaires / intégration / E2E

Tous les tests ne se valent pas, et surtout ils ne coûtent pas le même prix. La pyramide des tests est un modèle simple pour répartir votre effort : beaucoup de tests rapides à la base, peu de tests lents au sommet.

Les tests unitaires (base de la pyramide, ~70 %). Ils vérifient une seule fonction ou un seul composant, isolé du reste. Pas de base de données, pas de réseau, pas d'autres modules. Vous testez par exemple qu'une fonction `calculerTotalTTC(montantHT, tauxTVA)` renvoie bien `120` pour `(100, 20)`. Ils s'exécutent en millisecondes, vous pouvez en avoir des centaines, et quand l'un échoue vous savez *exactement* où est le problème. C'est le niveau où l'IA vous aide le plus : donnez-lui une fonction pure, elle génère une batterie de cas en quelques secondes.

Les tests d'intégration (milieu, ~20 %). Ils vérifient que plusieurs morceaux fonctionnent *ensemble* : votre code appelle vraiment la base de données, l'API répond, deux services se parlent. Exemple : « quand j'appelle `POST /commandes`, une ligne est bien créée en base et le stock est décrémenté ». Ils sont plus lents (dixièmes de seconde à quelques secondes) et plus fragiles, mais ils attrapent les bugs que les tests unitaires ne peuvent pas voir — typiquement les erreurs de branchement entre composants, là où l'IA se trompe souvent.

Les tests end-to-end (sommet, ~10 %). Ils simulent un vrai utilisateur qui traverse toute l'application, du clic dans le navigateur jusqu'à la base de données et retour. Exemple : « l'utilisateur remplit le formulaire d'inscription, valide, reçoit un email, se

connecte ». Ils sont lents (secondes à minutes), coûteux à maintenir et cassent pour un rien (un bouton déplacé). On en garde donc peu, réservés aux **parcours critiques** : inscription, paiement, action métier centrale.

🚫 **À éviter — la pyramide inversée** Le réflexe débutant, c'est de tout tester en E2E parce que « ça teste tout ». Résultat : une suite qui met 20 minutes à tourner, casse une fois sur trois pour de mauvaises raisons, et que plus personne ne lance. Un bug dans une fonction de calcul se teste en unitaire (2 ms), pas en pilotant un navigateur (30 s).

💡 **Astuce** Règle de décision rapide : « Est-ce que je teste **une logique** ou **un branchement** ? » Une logique (calcul, validation, transformation) → test unitaire. Un branchement (base, API, UI) → intégration ou E2E.

5.3 — Le TDD avec l'IA (RED → GREEN → REFACTOR)

Le TDD (Test Driven Development) inverse l'ordre habituel : vous écrivez le **test d'abord**, le code ensuite. Avec une IA, c'est une arme redoutable, parce que le test devient un cahier des charges exécutable. Au lieu de dire « code-moi une validation d'email » et de recevoir une usine à gaz de 40 lignes avec des cas que vous n'avez jamais demandés, vous écrivez les tests qui définissent *exactement* le comportement attendu, puis vous demandez à l'IA de les faire passer. Elle ne peut plus broder : son seul objectif est de rendre les tests verts.

Le cycle a trois temps :

- **RED** — vous écrivez un test pour un comportement qui n'existe pas encore. Vous le lancez : il échoue (rouge). Normal, le code n'existe pas.
- **GREEN** — vous écrivez (ou vous demandez à l'IA) le code *minimal* pour faire passer le test. Rien de plus.
- **REFACTOR** — le test est vert, vous pouvez maintenant nettoyer le code sans peur, puisque le test vous dira immédiatement si vous cassez quelque chose.

Déroulons un exemple complet en JavaScript avec Jest : une fonction `validerEmail(email)` qui renvoie `true` si l'email est valide, `false` sinon.

Étape 1 — RED : on écrit les tests d'abord.

```
// validerEmail.test.js
const validerEmail = require('./validerEmail');

describe('validerEmail', () => {
  test('accepte un email standard', () => {
    expect(validerEmail('maxime@kodesaas.com')).toBe(true);
  });

  test('refuse un email sans arobase', () => {
    expect(validerEmail('maxime.kodesaas.com')).toBe(false);
  });

  test('refuse un email sans domaine', () => {
    expect(validerEmail('maxime@')).toBe(false);
  });

  test('refuse une chaîne vide', () => {
    expect(validerEmail('')).toBe(false);
  });

  test('refuse une valeur non-string (null)', () => {
    expect(validerEmail(null)).toBe(false);
  });
});
```

On lance `npm test`. Résultat : **tout est rouge**, la fonction `validerEmail` n'existe même pas. C'est exactement ce qu'on veut. Ces cinq tests définissent noir sur blanc ce que « email valide » signifie *pour nous*, y compris les cas piège (chaîne vide, `null`) que l'IA oublie neuf fois sur dix quand on ne les impose pas.

Étape 2 — GREEN : on écrit le code minimal.

C'est ici qu'on peut demander à l'IA : « Écris `validerEmail` pour faire passer ces tests, sans rien ajouter d'autre. » On obtient :

```
// validerEmail.js
function validerEmail(email) {
  if (typeof email !== 'string' || email === '') {
    return false;
  }
  const regex = /^[^\s@]+@[^\s@]+\.[^\s@]+$/;
  return regex.test(email);
}

module.exports = validerEmail;
```

On relance `npm test` : **les cinq tests passent, tout est vert**. On a la preuve que la fonction fait ce qu'on a spécifié, ni plus ni moins. Le test `null` a forcé la garde `typeof email !== 'string'` — sans lui, l'IA aurait probablement planté sur `null.test()`.

Étape 3 — REFACTOR : on nettoie en confiance.

Le code est déjà correct. Si demain vous voulez durcir la regex ou extraire le motif dans une constante, vous le faites et vous relancez les tests. S'ils restent verts, votre refactoring est bon. S'ils passent au rouge, vous venez de casser un comportement — et vous le savez *tout de suite*, pas en production.

✅ À faire / ❌ À éviter en TDD avec l'IA

- ✅ Écrire les cas limites dans les tests **avant** de générer le code (vide, `null`, valeurs extrêmes).
- ✅ Demander explicitement le code « minimal pour faire passer les tests ».
- ❌ Laisser l'IA écrire les tests ET le code dans le même prompt sans les relire — vous perdez le rôle de garde-fou.
- ❌ Passer à l'étape suivante alors qu'un test est encore rouge.

5.4 — Les 4 piliers d'un code reprenable

Voici le vrai test de qualité, celui qui compte quand vous êtes freelance ou que vous passez un projet à un collègue : **le test du freelance**. Un dev externe, qui ne connaît rien à votre projet, doit pouvoir cloner le repo, comprendre l'architecture et lancer l'application en **moins de 30 minutes**. Si c'est le cas, votre code est reprenable. Sinon, vous avez construit une dette que quelqu'un paiera — souvent vous, dans six mois, quand vous aurez tout oublié. Le code généré par IA est particulièrement exposé : il marche, mais personne (pas même vous) ne sait *pourquoi* il est structuré comme ça. Quatre piliers résolvent ça.

Pilier 1 — Une structure lisible. Le dossier du projet doit raconter ce que fait l'application. Des noms de fichiers et de dossiers explicites (`services/`, `controllers/`, `validerEmail.js` et non `utils2.js`), une organisation cohérente, un fichier qui a une responsabilité claire. Quand l'IA vous propose de tout entasser dans un fichier de 800 lignes, découpez. La structure est la première documentation qu'un repreneur lit.

Pilier 2 — Des tests. C'est tout le sujet des sections précédentes. Une suite de tests n'est pas qu'un filet de sécurité : c'est de la documentation vivante. Un dev qui reprend le projet lit les tests pour comprendre ce que le code est censé faire, sans avoir à déchiffrer l'implémentation. Un `describe('validerEmail')` avec ses cas est plus clair que dix lignes de commentaires.

Pilier 3 — De la documentation utile, dont le `CLAUDE.md`. Un `README` qui répond à trois questions : c'est quoi ce projet, comment je l'installe, comment je le lance. Pas un roman — les commandes essentielles suffisent. Et puisque vous codez avec une IA, ajoutez un fichier `CLAUDE.md` à la racine : il donne à l'agent (et au prochain humain) le contexte du projet, les

conventions, les commandes de test, les pièges connus. C'est ce fichier qui fait qu'un nouvel arrivant — humain ou IA — devient productif en minutes au lieu d'heures.

Pilier 4 — Des conventions constantes. Un seul style de nommage, un formatage automatique (Prettier, ESLint, PHP-CS-Fixer...), une façon cohérente de gérer les erreurs et de structurer les fonctions. L'IA a tendance à changer de style à chaque prompt : imposez le vôtre via un linter configuré, et le code reste homogène quelle que soit la session. Un code cohérent se lit deux fois plus vite qu'un patchwork de styles.

💡 **Astuce — passez le test vous-même** Une fois par mois, clonez votre propre projet dans un dossier vierge et chronométrez-vous : combien de temps pour le lancer en suivant uniquement le README ? Si vous dépassez 30 minutes ou si vous devez deviner une étape, c'est votre doc qu'il faut corriger, pas votre mémoire.

✅ À faire / ❌ À éviter

- ✅ Maintenir le `README` et le `CLAUDE.md` à jour à chaque changement structurel.
- ✅ Configurer un linter dès le début du projet, pas à la fin.
- ❌ Se dire « je documenterai quand ce sera fini » — ce moment n'arrive jamais.
- ❌ Accepter que chaque fichier généré ait son propre style : imposez vos conventions à l'IA.

Partie 6 — Déploiement & mise en production

Votre appli tourne sur votre machine. Bravo — mais ça ne compte pas encore. Tant que personne d'autre ne peut y accéder, elle n'existe pas vraiment. Cette partie couvre le passage du « ça marche chez moi » au « c'est en ligne, sécurisé et surveillé ». Bonne nouvelle : pour un MVP, on peut faire ça proprement pour moins de 20 € HT/mois. Mauvaise nouvelle : chaque brique compte, et en oublier une (le HTTPS, le monitoring) se paie cher plus tard.

L'IA vous aide énormément ici — elle génère vos fichiers de config, vos commandes serveur, vos workflows. Mais elle ne remplace pas votre compréhension : vous devez savoir *quoi* déployer et *pourquoi*, sinon vous copiez-collez des commandes que vous ne pouvez ni déboguer ni sécuriser.

6.1 — Conteneuriser avec Docker

Le problème que Docker résout tient en une phrase : « ça marche chez moi ». Votre appli dépend d'une version précise de Node ou de PHP, d'une base de données, de variables d'environnement, de librairies système. Sur votre Mac, tout est en place. Sur le serveur, une version diffère et tout casse. Un **conteneur** règle ça : c'est un paquet qui embarque votre code **et** tout son environnement d'exécution, figé. Le même conteneur tourne à l'identique sur votre portable, sur le serveur, chez votre collègue.

Vocabulaire minimal. Une **image**, c'est le modèle figé (le gâteau photographié dans le livre de recettes). Un **conteneur**, c'est une instance qui tourne à partir de cette image (le gâteau réel que vous mangez). Une image se décrit dans un fichier texte, le **Dockerfile**, qui liste les étapes de construction. Exemple pour une petite app Node :

```
# Image de base : Node 20 en version "slim" (légère)
FROM node:20-slim

# Dossier de travail à l'intérieur du conteneur
WORKDIR /app

# On copie d'abord les manifestes de dépendances (optimise le cache)
COPY package*.json ./
RUN npm ci --omit=dev

# Puis le reste du code
COPY . .

# Le port que l'app écoute
EXPOSE 3000

# La commande lancée au démarrage du conteneur
CMD ["node", "server.js"]
```

Une vraie appli, c'est rarement un seul service : il y a l'app **et** une base de données, parfois un cache. Les faire tourner et communiquer à la main est pénible. **Docker Compose** orchestre tout ça dans un seul fichier `docker-compose.yml` que vous lancez avec `docker compose up` :

```
services:
  app:
    # Notre application
    build: .
    # Construit l'image depuis le Dockerfile local
    ports:
      - "3000:3000"
    # Port serveur:port conteneur
    environment:
      DATABASE_URL: postgres://app:secret@db:5432/appdb
    depends_on:
      - db
    # L'app démarre après la base
```

```
db:                                     # La base de données
  image: postgres:16                  # Image officielle, pas de build maison
  environment:
    POSTGRES_USER: app
    POSTGRES_PASSWORD: secret
    POSTGRES_DB: appdb
  volumes:
    - db_data:/var/lib/postgresql/data # Persiste les données

volumes:
  db_data:                             # Volume nommé : survit aux redémarrages
```

Le point clé du `volumes` : sans lui, chaque `docker compose down` effacerait votre base. Le volume nommé garde les données hors du conteneur, sur le disque de l'hôte.

✓ À faire / ✗ À éviter

- ✓ Partir d'une image officielle en version `-slim` ou `-alpine` : plus légère, moins de surface d'attaque.
- ✓ Copier `package.json` avant le reste du code pour profiter du cache Docker (rebuilt beaucoup plus rapides).
- ✗ Mettre des mots de passe en clair dans le Dockerfile ou le compose commité sur Git. Utilisez un fichier `.env` (non versionné) référencé par Compose.
- ✗ Stocker les données applicatives dans le conteneur sans volume : elles disparaissent au prochain déploiement.

💡 **Astuce** — Demandez à l'IA : « Génère-moi un Dockerfile multi-stage pour cette app ». Le multi-stage build compile dans une première image (avec tous les outils) et ne copie que le résultat final dans une image légère. Résultat : des images 3 à 5 fois plus petites, qui démarrent et se déploient plus vite.

6.2 — Où héberger : VPS, PaaS, Vercel

Trois familles pour héberger, du plus « à faire soi-même » au plus « clé en main ».

Le **VPS** (Virtual Private Server) : on vous loue une machine virtuelle nue, avec un accès administrateur complet. Vous installez et configurez tout vous-même. Plus de travail au départ, mais un contrôle total et un coût imbattable. C'est là que vous apprenez vraiment ce qui tourne sous votre app. Les fournisseurs courants : **OVHcloud**, **Scaleway** et **Plenit** (ex-Jotelulu) — hébergeurs français, un vrai atout pour le RGPD, sauvegardes souvent incluses —, **Hostinger** (lituanien, donc européen) ou **DigitalOcean** et ses *droplets* (acteur international, interface très claire, documentation réputée). Les tarifs d'entrée de gamme se ressemblent (~4-6 €/mois) ; privilégiez l'UE dès que vous traitez des données personnelles. Attention : pour le RGPD, ce qui compte est la **localisation du datacenter** (la région où vos données sont hébergées), pas la nationalité du fournisseur — un fournisseur non français peut parfaitement héberger vos données dans un datacenter européen.

Le **PaaS** (Platform as a Service — Render, Railway, Fly.io) : vous poussez votre code, la plateforme gère serveur, réseau, HTTPS, parfois la base. Confortable, mais vous payez ce confort, et la facture grimpe avec la charge.

Vercel est un cas particulier, très populaire pour le front et les apps JavaScript (Next.js en tête). Vous connectez votre dépôt GitHub, et chaque `push` déclenche un déploiement automatique, avec une URL de preview par branche. Le modèle est *serverless* : votre code s'exécute à la demande dans des fonctions, sans serveur à gérer. Idéal pour un front moderne ou une API légère ; à surveiller dès que vous avez des traitements longs (les fonctions ont un *timeout*, 10 s par défaut, configurable jusqu'à quelques minutes selon le plan) ou une grosse base de données — dans ces cas, un backend sur VPS reste plus adapté. Beaucoup de projets combinent : **front sur Vercel, backend + base sur un VPS**.

Ordres de grandeur (2026) pour tenir le budget < 20 € HT/mois :

Formule	Ressources	Prix indicatif	Pour quoi
VPS entrée de gamme	1 vCPU, 1-2 Go RAM	~5 €/mois	MVP, side-project, démo client
VPS confort	2 vCPU, 4 Go RAM	~10-15 €/mois	MVP avec base de données qui respire

Vercel (Hobby)	Serverless	Gratuit (usage perso/démo)	Front Next.js, portfolio, MVP léger
Nom de domaine	—	~10-15 €/an	Indispensable (voir 6.3)

✅ À faire / ❌ À éviter

- ✅ Choisir un hébergeur dont les serveurs (datacenter) sont en France ou en UE si vous traitez des données personnelles (RGPD).
- ✅ Sur un VPS, dès la première connexion : créer un utilisateur non- `root` , désactiver le login SSH par mot de passe au profit des clés, installer un firewall (`ufw`).
- ❌ Rester connecté en `root` pour tout faire « parce que c'est plus simple ». Une faille dans votre app = votre serveur entier compromis.
- ❌ Choisir Vercel pour un backend lourd avec traitements longs : le serverless n'est pas fait pour ça.

💡 **Astuce** — Faites au moins un déploiement VPS à la main dans votre vie. C'est ce qui sépare le vibecodeur qui « déploie sur Vercel sans savoir pourquoi » du profil qui maîtrise sa prod et débogue dix fois mieux.

6.3 — Les briques de prod minimales

Un serveur nu ne suffit pas à servir une appli correctement. Quatre briques s'assemblent, chacune avec un rôle précis.

Le reverse proxy est le portier de votre serveur. Il reçoit toutes les requêtes web (port 443) et les redirige vers le bon conteneur en interne. Il gère aussi le HTTPS, sert les fichiers statiques, et peut router plusieurs sites sur une même machine. Trois choix courants : **nginx** (le standard, robuste, config un peu verbeuse), **Caddy** (le plus simple — HTTPS automatique en une ligne, idéal débutant), **Traefik** (pensé pour Docker, se configure via des labels sur vos conteneurs). Pour un MVP, **Caddy** fait gagner un temps fou.

La base de données stocke vos données de façon persistante (voir Partie 8 pour bien la choisir). En prod, deux options : la faire tourner dans un conteneur Docker (simple, vous maîtrisez tout) ou utiliser une base managée (sauvegardes automatiques, mais coût en plus).

Le nom de domaine est l'adresse lisible (`monapp.fr`) qui pointe vers l'IP de votre serveur. On l'achète chez un registrar, puis on configure un enregistrement **DNS** de type `A` qui associe le domaine à l'adresse IP du VPS.

Le HTTPS chiffre le trafic entre le navigateur et votre serveur (le petit cadenas). Ce n'est pas optionnel : sans lui, les mots de passe circulent en clair et les navigateurs affichent « Non sécurisé ». **Let's Encrypt** fournit des certificats gratuits et automatiques. Caddy et Traefik les obtiennent et les renouvellent tout seuls ; avec nginx, on utilise l'outil `certbot` .

Schéma du chemin d'une requête :

```

Navigateur —HTTPS→ [ Reverse proxy ] → [ Conteneur app ] → [ Base de données ]
(monapp.fr)          (Caddy : 443,      (Node : 3000)          (Postgres : 5432,
                        certificat Let's   jamais exposé au net)
                        Encrypt auto)

```

✅ À faire / ❌ À éviter

- ✅ N'exposer au réseau public **que** le reverse proxy (ports 80/443). L'app et la base restent joignables uniquement en interne.
- ✅ Vérifier que le renouvellement automatique des certificats fonctionne — un certificat expiré casse tout le site du jour au lendemain.
- ❌ Exposer le port de la base de données (5432, 3306) sur Internet. C'est l'une des premières choses que scannent les bots.

6.4 — Monitoring d'erreurs : savoir quand ça casse

En local, quand ça plante, vous voyez l'erreur dans votre console. En prod, l'erreur arrive chez un utilisateur, à 23h, et vous n'en savez **rien** — sauf s'il prend la peine de vous écrire (il ne le fera pas, il partira). Le monitoring d'erreurs comble ce trou : dès

qu'une exception se produit, un outil la capture et vous alerte, avec tout le contexte pour la reproduire.

Les outils de référence : **Sentry** (le leader, plan gratuit généreux) et **GlitchTip** (alternative open-source, compatible avec les SDK Sentry, que vous pouvez auto-héberger sur votre VPS). Le principe est identique : vous ajoutez leur librairie à votre app, vous collez une clé (le *DSN*), et chaque erreur non gérée remonte automatiquement.

Ce qu'un bon monitoring capture pour chaque erreur : le message et la *stack trace* (la ligne exacte du code fautif), l'URL et l'action en cours, le navigateur/OS de l'utilisateur, une version anonymisée du contexte utilisateur, et surtout un **regroupement** : 400 fois la même erreur = un seul ticket, avec le compteur. Vous passez de « je découvre les bugs quand un client râle » à « je vois le pic d'erreurs 30 secondes après le déploiement et je *rollback* avant que ça se voie ».

✅ À faire / ❌ À éviter

- ✅ Brancher le monitoring **dès le premier déploiement**, pas « quand j'aurai le temps ». Le premier bug de prod arrivera avant ce moment-là.
- ✅ Configurer une alerte (mail, Slack) sur les nouvelles erreurs, pas juste un tableau de bord que vous ne regarderez jamais.
- ❌ Envoyer des données sensibles (mots de passe, tokens, numéros de carte) dans les rapports d'erreur. Les SDK ont des filtres — activez-les.

💡 **Astuce** — GlitchTip auto-hébergé sur votre VPS revient à ~0 € et garde les données chez vous. Le SDK étant compatible Sentry, vous pouvez migrer de l'un à l'autre sans changer votre code.

6.5 — CI/CD avec GitHub Actions

CI/CD signifie *Continuous Integration / Continuous Deployment*. En clair : à chaque fois que vous fusionnez du code sur votre branche principale, une machine lance automatiquement vos tests, puis (s'ils passent) déploie la nouvelle version. Fini le déploiement manuel à la main, source d'oublis d'étape et d'erreurs à 2h du matin.

Le mécanisme s'appelle un **pipeline** : une suite d'étapes exécutées dans l'ordre. Avec **GitHub Actions**, tout se décrit dans un fichier `.github/workflows/deploy.yml`. La règle d'or : le déploiement ne se déclenche **que si les tests passent**. Un test rouge = pas de mise en prod. Exemple minimal, deux étapes (`test` puis `deploy`) :

```
name: CI/CD
on:
  push:
    branches: [main]          # Se déclenche à chaque push sur main

jobs:
  test:
    # Étape 1 : on teste
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - uses: actions/setup-node@v4
        with:
          node-version: '20'
      - run: npm ci
      - run: npm test          # Si un test échoue, le pipeline s'arrête ici

  deploy:
    # Étape 2 : on déploie
    needs: test               # Ne démarre QUE si "test" a réussi
    runs-on: ubuntu-latest
    steps:
      - name: Déploiement sur le VPS via SSH
        uses: appleboy/ssh-action@v1
        with:
          host: ${ secrets.VPS_HOST }    # Secrets stockés dans GitHub
```

```
username: ${ secrets.VPS_USER }}
key: ${ secrets.SSH_KEY }}
script: |
  cd /opt/monapp
  git pull
  docker compose up -d --build      # Reconstruct et relance
```

La ligne `needs: test` est le cœur du dispositif : elle garantit qu'un code cassé n'atteint jamais la prod. Les identifiants du serveur ne sont jamais écrits en clair — ils vivent dans les **secrets** GitHub (Settings → Secrets), et le workflow les injecte via `${ secrets.NOM }}`. Pour verrouiller encore : activez la **protection de branche** sur `main` (Settings → Branches) pour interdire le push direct et exiger que les tests passent avant tout merge.

✅ À faire / ❌ À éviter

- ✅ Toujours faire passer les tests **avant** le déploiement dans le pipeline (`needs: test`). Un pipeline qui déploie sans tester ne sert à rien.
- ✅ Stocker clés SSH, tokens et mots de passe dans les secrets du dépôt, jamais dans le fichier YAML.
- ❌ Déclencher le déploiement sur **toutes** les branches. Réservez-le à `main` (ou une branche *production* dédiée).
- ❌ Négliger le rollback : gardez un moyen de revenir vite à la version précédente (tag Git, image précédente) quand un déploiement tourne mal.

💡 **Astuce** — Commencez petit : un pipeline qui lance juste vos tests à chaque push, sans déploiement auto. Vous ajoutez l'étape `deploy` quand vous êtes en confiance. Un CI qui teste, même sans CD, vous évite déjà 80 % des régressions envoyées en prod.

6.6 — Les tâches de fond (jobs asynchrones) avec Trigger.dev

Toutes les actions ne doivent pas se faire « pendant que l'utilisateur attend ». Envoyer 500 emails, générer un PDF lourd, appeler une API IA qui met 30 secondes, relancer un traitement chaque nuit : si vous faites ça dans la requête web, l'utilisateur poireaute et finit par un *timeout*. La solution, ce sont les **tâches de fond** (jobs asynchrones) : l'action est mise dans une file, traitée en arrière-plan par un *worker*, et l'utilisateur reçoit une réponse immédiate.

Historiquement, ça demandait de gérer soi-même une file (Redis) et des workers — lourd à mettre en place et à surveiller. Des plateformes comme **Trigger.dev** simplifient énormément : vous écrivez votre tâche en TypeScript comme une fonction normale, vous la déclenchez depuis votre code, et la plateforme gère la file, les *retries* automatiques en cas d'échec, la planification (cron), et un tableau de bord pour suivre chaque exécution. Cas d'usage typiques pour un SaaS vibecodé :

- Envoyer les emails transactionnels sans bloquer l'inscription.
- Lancer un traitement IA long (résumé, génération) et notifier l'utilisateur une fois fini.
- Tâches planifiées : rapport hebdomadaire, nettoyage nocturne, relances automatiques.
- Webhooks entrants à traiter de façon fiable (avec retry si l'API distante tombe).

L'idée à retenir : **tout ce qui est lent, faillible ou planifié sort de la requête web** et part en tâche de fond. Vous gagnez en réactivité (l'utilisateur n'attend pas) et en robustesse (une tâche qui échoue est réessayée automatiquement, pas perdue).

✅ À faire / ❌ À éviter

- ✅ Sortir de la requête tout traitement > 1-2 secondes ou qui appelle une API externe.
- ✅ Rendre les tâches idempotentes (les rejouer ne double pas l'effet) — un retry ne doit pas envoyer deux fois le même email.
- ❌ Faire un `sleep` ou un gros calcul directement dans un contrôleur web.
- ❌ Ignorer les échecs silencieux : surveillez le tableau de bord des jobs comme vous surveillez vos erreurs.

💡 **Astuce** — Une alternative auto-hébergée existe pour chaque langage (files Redis + workers : BullMQ en Node, Messenger en Symfony, Celery en Python). Trigger.dev fait gagner du temps quand vous voulez le tableau de bord, les retries et le cron sans rien administrer.

En résumé : conteneurisez (Docker), choisissez votre hébergement (VPS, PaaS ou Vercel selon le besoin), assemblez les quatre briques (reverse proxy, base, domaine, HTTPS), branchez un monitoring d'erreurs dès le jour 1, automatisez tests + déploiement avec GitHub Actions, et sortez les traitements lourds en tâches de fond. Chacune de ces briques est générable en grande partie par l'IA — mais c'est votre compréhension du *pourquoi* qui fait la différence entre un déploiement qui tient et un château de cartes.

Partie 7 — Sécurité & conformité

La sécurité n'est pas une étape que l'on ajoute à la fin, juste avant la mise en ligne. C'est une contrainte que l'on intègre au moment où l'on écrit la première ligne — ou plutôt, quand l'IA l'écrit pour vous. Un modèle qui génère du code produit ce qui fonctionne, pas ce qui est sûr : il vous donnera volontiers un endpoint qui expose toute votre base si vous ne lui demandez rien de plus. Cette partie vous donne les réflexes, la grille de lecture (OWASP), une méthode d'audit assistée par IA, la conduite d'un pentest, et les limites légales et réglementaires à ne jamais franchir.

7.1 — Les réflexes de base

Quatre habitudes vous évitent 80 % des incidents évitables. Elles ne demandent aucune expertise, juste de la discipline.

Ne jamais commiter un secret. Une clé d'API, un mot de passe de base de données, un token : dès que ça part sur un dépôt Git (même privé), considérez-le comme compromis. GitHub scanne les commits publics et les bots aspirent les clés en quelques minutes. Le problème avec Git, c'est que l'historique garde tout : supprimer la clé dans un commit suivant ne l'efface pas, elle reste visible dans l'historique. Si ça arrive, révoquez la clé immédiatement — ne comptez jamais sur la discrétion.

Utiliser `.env` et les variables d'environnement. Vos secrets vivent dans un fichier `.env` local, jamais versionné. Le code lit ces valeurs via l'environnement (`process.env.STRIPE_KEY` , `getenv('DB_PASSWORD')`). En production, vous injectez ces variables via le panneau de votre hébergeur, pas dans un fichier. Vous fournissez un `.env.example` avec les clés mais sans les valeurs, pour documenter ce qu'il faut renseigner.

```
# .env (JAMAIS commité)
DATABASE_URL=postgres://user:motdepasse@localhost:5432/app
STRIPE_SECRET_KEY=sk_live_51H...
JWT_SECRET=une-chaine-longue-et-aleatoire

# .env.example (commité, sert de modèle)
DATABASE_URL=
STRIPE_SECRET_KEY=
JWT_SECRET=
```

Le `.gitignore`. C'est le garde-barrière. Un fichier `.gitignore` à la racine liste ce que Git doit ignorer. Ajoutez-y `.env` **avant** votre premier commit — pas après.

```
# Secrets & config locale
.env
.env.local
*.pem
*.key

# Dépendances & build
node_modules/
vendor/
dist/
```

Les en-têtes de sécurité HTTP. Ce sont des instructions que votre serveur envoie au navigateur pour restreindre ce qu'il a le droit de faire. Quatre à connaître :

- `X-Frame-Options: DENY` — empêche que votre site soit affiché dans une iframe sur un site pirate (protège du *clickjacking*).
- `Content-Security-Policy` (CSP) — liste blanche des sources autorisées pour les scripts, images, styles. C'est la meilleure défense contre le XSS, mais aussi la plus délicate à régler.
- `Strict-Transport-Security` (HSTS) — force le navigateur à toujours utiliser HTTPS, jamais HTTP.

- `X-Content-Type-Options: nosniff` — empêche le navigateur de « deviner » le type d'un fichier et de l'exécuter comme un script alors qu'il ne devrait pas.

✅ **À faire** : ajouter `.env` au `.gitignore` avant le premier commit · révoquer toute clé exposée · vérifier ses en-têtes sur securityheaders.com. 🚫 **À éviter** : coller une clé « juste pour tester » dans le code · pousser un `.env` en se disant « le repo est privé » · désactiver HTTPS en prod pour « aller plus vite ».

💡 **Astuce** : demandez à votre IA « génère-moi un middleware qui pose les en-têtes de sécurité recommandés (CSP, HSTS, X-Frame-Options, nosniff) pour mon app Express/Symfony ». Elle produit une base correcte que vous ajustez ensuite.

7.2 — L'OWASP Top 10 pour vibecoders

L'OWASP Top 10 est la liste de référence des dix familles de failles web les plus répandues. Vous n'avez pas besoin de la connaître par cœur, mais vous devez savoir la reconnaître pour prompter votre IA correctement et relire son code avec les bons réflexes. Voici les quatre qui touchent le plus souvent les projets vibecodés.

Contrôle d'accès défaillant (dont l'IDOR). La faille numéro un. Elle survient quand l'application vérifie *que vous êtes connecté*, mais pas *que vous avez le droit d'accéder à cette ressource précise*. L'IDOR (*Insecure Direct Object Reference*) en est le cas le plus courant : un endpoint accepte un identifiant dans l'URL et renvoie la donnée sans vérifier qu'elle vous appartient.

```
GET /api/invoices/1042    → votre facture, OK
GET /api/invoices/1043    → la facture du client d'à côté... renvoyée aussi !
```

Le code généré ressemble souvent à `SELECT * FROM invoices WHERE id = :id`. Il manque la clause qui change tout : `AND owner_id = :utilisateur_connecté`. Avec des IDs entiers séquentiels, un attaquant incrémente simplement le numéro et aspire toute la base. **La règle : toute requête sur une ressource doit filtrer sur le propriétaire connecté, côté serveur, systématiquement.**

Injection. Quand une entrée utilisateur est insérée telle quelle dans une requête SQL, une commande shell ou du HTML. Exemple SQL : `"SELECT * FROM users WHERE email = '' + email + ''"` — un attaquant saisit `' OR '1'='1` et contourne tout. La parade est universelle : **requêtes paramétrées** (le fameux `?` ou `:param`), jamais de concaténation de chaînes.

Exposition de données sensibles. Mots de passe stockés en clair, jetons dans les logs, messages d'erreur qui révèlent la structure de la base, endpoint `/api/users` qui renvoie tout l'objet utilisateur (y compris le hash du mot de passe). Les mots de passe se hachent (bcrypt, argon2), jamais on ne les chiffre « pour pouvoir les relire ».

Mauvaise configuration. La catégorie fourre-tout mais redoutable : mode debug activé en production, page d'admin accessible sans authentification, bucket de stockage public, CORS ouvert à `*`, ports de base de données exposés sur Internet. Souvent, ce n'est pas le code qui est en cause mais un réglage laissé par défaut.

#	Faillle OWASP	En une phrase	Exemple concret
A01	Contrôle d'accès défaillant	On ne vérifie pas que l'utilisateur a le droit d'accéder à cette ressource	IDOR : <code>/invoices/1043</code> renvoie la facture d'un autre
A02	Défaillances cryptographiques	Données sensibles non (ou mal) chiffrées/hachées	Mots de passe stockés en clair
A03	Injection	Une entrée utilisateur exécutée comme du code/une requête	<code>' OR '1'='1</code> dans un champ email
A04	Conception non sécurisée	La logique métier elle-même autorise un abus	Réinitialiser le mot de passe sans vérifier l'identité
A05	Mauvaise configuration	Réglage par défaut ou permissif laissé en place	Mode debug actif, admin sans mot de passe

A06	Composants vulnérables	Dépendances obsolètes avec failles connues	Librairie non mise à jour, CVE publique
A07	Défaillances d'authentification	Login contournable ou trop faible	Pas de limite sur les tentatives, session qui n'expire jamais
A08	Manque d'intégrité	Données/code acceptés sans vérification de source	Mise à jour non signée, désérialisation dangereuse
A09	Défaut de journalisation	On ne détecte pas l'attaque faute de logs	Aucune trace d'une série de connexions échouées
A10	SSRF	Le serveur est manipulé pour requêter une ressource interne	Une URL fournie par l'utilisateur pointe vers 169.254.169.254

💡 **Astuce** : dans votre prompt, précisez le contexte de sécurité. « Écris cet endpoint de récupération de facture en filtrant sur l'utilisateur authentifié et en utilisant une requête paramétrée » donne un tout autre résultat que « écris un endpoint qui récupère une facture par ID ».

7.3 — L'audit de sécurité piloté par IA

Vous pouvez orchestrer des agents pour auditer votre propre SaaS. L'idée n'est pas de remplacer un pentesteur professionnel, mais d'attraper les erreurs grossières avant qu'elles ne partent en production. Le processus se déroule en quatre phases, que vous confiez idéalement à des agents spécialisés successifs.

1. **Reconnaissance** — inventorier la surface d'attaque : quelles routes, quels endpoints d'API, quels formulaires, quelles pages authentifiées vs publiques, quelles dépendances. L'agent lit votre code et produit une cartographie.
2. **Mapping** — pour chaque endpoint, identifier ce qui touche à des données sensibles ou à une action privilégiée (paiement, suppression, accès à des données d'autres utilisateurs).
3. **Tests OWASP** — passer chaque point sensible au crible du Top 10 : ce endpoint filtre-t-il sur le propriétaire ? Utilise-t-il des requêtes paramétrées ? Vérifie-t-il les droits ? L'agent lit le code et signale les manques.
4. **Rapport** — consolider en une liste de *findings* priorisés, chacun avec sa localisation, son impact et sa correction.

La priorisation est le cœur du travail. Un audit qui rend 40 remarques sans hiérarchie est inutilisable. Classez en trois niveaux :

- **P0 — critique, à corriger avant tout** : exploitable à distance, sans authentification, avec impact majeur (fuite de données, prise de contrôle).
- **P1 — important, à corriger vite** : nécessite un compte ou une condition particulière, mais impact réel.
- **P2 — à traiter** : durcissement, bonnes pratiques, risque faible ou théorique.

✅ **À faire** : relancer l'audit à chaque évolution majeure · traiter tous les P0 avant de déployer · vérifier manuellement chaque finding (l'IA produit des faux positifs). 🚫 **À éviter** : traiter le rapport comme une vérité absolue · corriger en masse sans comprendre · ignorer les P2 indéfiniment (ils s'accumulent).

💡 **Astuce** : demandez à l'agent de fournir, pour chaque finding, le correctif exact et le pourquoi. Vous apprenez en corrigeant, et vous vérifiez que l'IA n'hallucine pas une faille inexistante.

7.4 — Conduire un pentest : méthode et exemple concret

Auditer son code (7.3) repère les failles à *la lecture*. Le **pentest** (test d'intrusion) va plus loin : il attaque l'application en *fonctionnement*, comme le ferait un vrai attaquant, pour prouver qu'une faille est réellement exploitable. La nuance est capitale : une remarque « ce endpoint ne filtre peut-être pas les droits » devient « voici la facture d'un autre client que j'ai récupérée en changeant un chiffre dans l'URL ». La preuve, pas la supposition.

Un pentest assisté par IA suit cinq phases. Vous orchestrez des agents, mais vous gardez la main sur le périmètre et l'interprétation.

1. **Reconnaissance** — cartographier la cible sans rien attaquer : DNS, en-têtes HTTP, `robots.txt`, `sitemap.xml`, certificats, technologies détectées (via les en-têtes comme `X-Powered-By`). On dresse la surface d'attaque.

2. **Authentification & endpoints** — se connecter avec un compte de test, lister les routes authentifiées vs publiques, repérer celles qui touchent des données sensibles.
3. **Tests d'exploitation** — IDOR (incrémenter des identifiants), injection (SQL, commandes), énumération d'utilisateurs, contournement de droits, en lecture seule et sans rien détruire.
4. **Vérification défensive** — contrôler ce qui *résiste* : jeton CSRF présent ? cookies `HttpOnly` / `Secure` / `SameSite` ? mode debug désactivé ? fichiers `.env` inaccessibles ?
5. **Rapport** — consolider les *findings* priorisés, chacun avec preuve, impact et correctif.

Voici un extrait de rapport réel (anonymisé) issu d'un audit sur un SaaS de gestion de contacts, pour montrer le niveau attendu :

```
[P0 – HAUTE] IDOR – énumération d'utilisateurs via ID entier séquentiel
Endpoint : GET /messaging/start/{id} (authentification requise)
Preuve   : /messaging/start/1 → "Utilisateur A" ; /messaging/start/2 →
           "Utilisateur B" ; ... l'incrément expose nom, photo, date
           d'inscription de TOUS les membres.
Impact   : annuaire complet des membres reconstituable → violation RGPD,
           facilite le phishing ciblé.
Correctif: remplacer l'ID entier par un UUID + vérifier le droit d'accès
           + rate limiting (ex. 10 req/min).

[P0 – HAUTE] Photos de profil accessibles sans authentification
Endpoint : GET /api/.../avatars/user_{id}/{fichier} (aucune auth)
Preuve   : requête sans cookie de session → HTTP 200, image renvoyée.
Impact   : collecte en masse des photos de profil (données personnelles ;
           biométriques au sens de l'art. 9 seulement si reconnaissance faciale).
Correctif: exiger l'authentification sur /api/, ou URLs signées à durée limitée.
```

Le classement **P0/P1/P2** est le cœur du livrable : deux failles P0 combinées (énumération + photos non protégées) transforment deux « petits » défauts en fuite massive de données personnelles. Un rapport sans priorisation est illisible ; un rapport qui hiérarchise est actionnable.

✅ **À faire** : toujours tester avec un compte dédié · prouver chaque finding (capture, requête) · nettoyer les artefacts créés (comptes/données de test) · vérifier manuellement les findings de l'IA (elle produit des faux positifs). 🚫 **À éviter** : lancer des tests destructifs (suppression, DoS, brute-force) · exfiltrer de vraies données dans le rapport · tester sans le cadre légal de la section suivante.

💡 **Astuce** : conservez la liste des « points positifs » (ce qui résiste) dans le rapport. Un audit qui ne dit que le négatif fait peur au client sans le rassurer sur ce qui est déjà solide. Le professionnalisme, c'est l'équilibre.

7.5 — Le cadre légal

Tout ce qui précède s'applique à **votre** application. Le moment où vous testez un système qui ne vous appartient pas, vous changez de monde : vous entrez dans le champ pénal. Ce point n'est pas une recommandation, c'est une limite non négociable.

Jamais de test d'intrusion sans autorisation écrite. Scanner les ports d'un site, tester un formulaire d'injection, tenter un IDOR sur une application que vous ne possédez pas — même « pour voir », même sans rien casser — constitue une infraction. En France, l'accès ou le maintien frauduleux dans un système de traitement automatisé de données est réprimé par les articles 323-1 et suivants du Code pénal (jusqu'à plusieurs années de prison et de lourdes amendes). L'intention ne vous protège pas : le simple fait de tester sans droit suffit.

Définir le périmètre (scope). Une autorisation n'est pas un blanc-seing. Elle précise noir sur blanc : quels domaines et sous-domaines, quelles adresses IP, quels types de tests sont permis, sur quelle fenêtre de temps, et ce qui est explicitement **hors** périmètre. Un test lancé sur un sous-domaine non couvert vous met en faute, même avec une autorisation par ailleurs valide.

Ne tester que ce que vous possédez ou êtes autorisé à tester. Pour vous entraîner légalement, il existe des terrains prévus pour ça : environnements délibérément vulnérables (OWASP Juice Shop, DVWA, PortSwigger Web Security Academy) que vous installez chez vous, ou programmes de *bug bounty* (HackerOne, YesWeHack) dont les règles définissent précisément le périmètre

autorisé. Le principe est simple : ou bien c'est votre infrastructure, ou bien vous avez un document qui vous y autorise. Il n'y a pas de zone grise.

✓ **À faire** : obtenir une autorisation écrite et datée avant tout test externe · lire et respecter le périmètre à la lettre · s'entraîner sur des cibles conçues pour ça. 🚫 **À éviter** : « je scanne vite fait pour voir » sur un site tiers · dépasser le périmètre « puisque j'y suis » · confondre bug bounty et permission de tout tester.

💡 **Astuce** : rédigez un modèle simple d'autorisation (parties, périmètre, dates, types de tests, contact d'urgence) et faites-le signer avant chaque mission. C'est votre seule protection réelle, et celle de votre client.

7.6 — RGPD & le règlement IA européen (AI Act)

Construire vite avec l'IA ne vous dispense pas du droit. Deux textes européens encadrent ce que vous faites : le **RGPD** (données personnelles) et le **règlement IA** — l'AI Act (Règlement (UE) 2024/1689) — dès que votre produit intègre de l'intelligence artificielle. Les ignorer, c'est risquer des sanctions lourdes et perdre la confiance des utilisateurs.

Le RGPD, en réflexes de vibecodeur. Dès qu'une donnée permet d'identifier une personne (nom, email, photo, adresse IP), le RGPD s'applique. Les principes à intégrer *dès la conception* (« privacy by design ») :

- **Minimisation** — ne collectez que les données réellement nécessaires. Pas de champ « juste au cas où ».
- **Finalité** — chaque donnée a une raison d'être documentée. On ne réutilise pas une donnée collectée pour X à des fins Y sans base légale.
- **Consentement & base légale** — cases à cocher non pré-cochées, politique de confidentialité claire, registre des traitements.
- **Droits des personnes** — accès, rectification, suppression (« droit à l'oubli »), portabilité. Votre app doit pouvoir *supprimer* réellement un utilisateur, pas juste le désactiver.
- **Sécurité** — chiffrement, contrôle d'accès, notification d'une fuite sous 72 h à la CNIL. C'est le lien direct avec tout ce chapitre : une faille IDOR qui expose des données personnelles (photos, emails...), c'est une violation RGPD.

L'AI Act, le nouveau venu. Entré en vigueur en 2024 et applicable progressivement jusqu'en 2026-2027, il classe les systèmes d'IA par niveau de risque et impose des obligations proportionnées :

Niveau de risque	Exemples	Obligations
Inacceptable (interdit)	Notation sociale, manipulation comportementale, biométrie de masse	Interdiction pure et simple
Élevé	IA de recrutement, scoring crédit, santé, éducation, tri de CV	Documentation, supervision humaine, tests, transparence, enregistrement
Limité	Chatbots, génération de contenu	Transparence : informer l'utilisateur qu'il parle à une IA / que le contenu est généré
Minimal	Filtres anti-spam, suggestions	Aucune obligation spécifique

Pour un SaaS vibecodé, deux cas fréquents. Si votre IA aide à une **décision sur des personnes** (trier des candidatures, noter un dossier), vous êtes probablement en risque *élevé* : supervision humaine obligatoire, traçabilité des décisions, information des personnes. Si votre IA se contente de **générer du contenu ou de discuter** (chatbot, assistant), vous êtes en risque *limité* : il suffit d'indiquer clairement que c'est une IA.

Le cas d'école : le tri de CV. C'est l'exemple que la CNIL surveille de près. Utiliser une IA pour trier des candidatures est autorisé — mais **prononcer un refus de manière entièrement automatisée, sans qu'un humain ne contrôle la décision, est interdit** (RGPD article 22 : droit de ne pas faire l'objet d'une décision purement automatisée à effet significatif ; AI Act : le recrutement est un usage à risque élevé qui exige une supervision humaine). Le signal qui trahit l'infraction est simple : si un candidat dépose son CV à 23h et reçoit un refus cinq minutes plus tard, aucun humain n'a relu son dossier — c'est l'IA seule qui l'a écarté. La CNIL contrôle précisément ce type de pratique. La règle pour votre produit : **une IA peut classer, présélectionner, aider — mais un humain doit valider tout refus** (ou toute décision défavorable), et le candidat doit pouvoir demander un réexamen.

✅ **À faire** : tenir un registre des traitements dès le premier utilisateur · afficher « contenu généré par IA » / « vous discutez avec un assistant IA » · prévoir une supervision humaine sur toute décision automatisée touchant une personne · permettre la suppression réelle des données. 🚫 **À éviter** : entraîner un modèle sur des données personnelles sans base légale · automatiser une décision (embauche, crédit) sans contrôle humain · considérer que « c'est juste un MVP » exonère du RGPD (c'est faux dès le premier vrai utilisateur).

💡 **Astuce** : intégrez la conformité comme une contrainte dans votre `CLAUDE.md` et votre spec, au même titre que la sécurité. Un audit de conformité (mené par un DPO ou un juriste) sur un produit pensé « privacy by design » coûte dix fois moins cher qu'une mise en conformité rétroactive. Et c'est un argument commercial : « conforme RGPD et AI Act » rassure vos clients.

Partie 8 — Choisir et gérer ses données

La base de données, c'est la mémoire de votre application — et souvent la décision technique la plus structurante, celle qu'on paie le plus cher si on se trompe. L'IA vous génère volontiers du code pour n'importe quelle base ; encore faut-il savoir laquelle choisir et pourquoi. Cette partie vous donne la grille de décision, puis passe en revue les options concrètes : relationnel, NoSQL, bases managées, et même no-code.

8.1 — Relationnel vs NoSQL : la vraie question

Deux grandes familles de bases existent, et le choix conditionne tout le reste.

Les bases relationnelles (SQL). Les données sont rangées dans des **tables** (lignes et colonnes), avec un schéma défini à l'avance et des **relations** entre elles (un contact appartient à une organisation, une inscription pointe vers un événement). Elles garantissent la cohérence : impossible d'insérer une inscription qui référence un événement inexistant. On les interroge avec le langage **SQL**. C'est le choix par défaut, et le bon, pour l'écrasante majorité des SaaS — dès que vos données ont des relations claires (et elles en ont presque toujours).

Les bases NoSQL. Elles rangent les données autrement : en **documents** (des objets JSON, comme MongoDB), en clé-valeur, en colonnes ou en graphes. Pas de schéma rigide imposé, une grande souplesse, et une capacité à encaisser d'énormes volumes en se répartissant sur plusieurs serveurs. Le prix de cette souplesse : c'est à vous de garantir la cohérence, et les requêtes qui croisent beaucoup de données sont plus laborieuses.

La règle simple pour un vibecodeur : **commencez en relationnel**. Vous choisissez le NoSQL seulement quand un besoin précis le justifie — volumes massifs, données sans structure fixe, débit d'écriture extrême. Pour un MVP de SaaS classique (contacts, événements, utilisateurs, facturation), le relationnel gagne à tous les coups : plus sûr, mieux outillé, et l'IA le maîtrise mieux.

✅ À faire / ❌ À éviter

- ✅ Partir sur du relationnel par défaut, et ne bifurquer que sur un besoin prouvé.
- ✅ Modéliser vos tables et relations avant de coder (voir Partie 2.5).
- ❌ Choisir NoSQL « parce que c'est plus moderne » — c'est un outil spécialisé, pas un défaut.
- ❌ Mélanger cinq bases différentes dans un MVP : une seule, bien maîtrisée, suffit.

8.2 — Les bases relationnelles : PostgreSQL, MySQL, MariaDB

Trois moteurs relationnels dominant, tous gratuits et open-source. Ils font globalement le même travail ; les nuances comptent surtout à grande échelle.

PostgreSQL — la référence actuelle pour un nouveau projet. Robuste, très respectueux du standard SQL, riche en fonctionnalités avancées (types JSON natifs, recherche plein texte, extensions comme la recherche vectorielle utile pour l'IA — voir Partie 9). C'est le choix recommandé par défaut : vous ne serez jamais bloqué par ses limites.

MySQL — historiquement le plus répandu du web, très bien documenté, un peu plus simple d'approche. Un choix solide, notamment si votre hébergement ou votre framework le pousse. La différence avec PostgreSQL est mince pour un MVP.

MariaDB — un dérivé de MySQL, créé en 2009 par le fondateur même de MySQL (Michael Widenius), par anticipation du rachat de MySQL par Oracle — rachat survenu via l'acquisition de Sun Microsystems, finalisée en 2010. Compatible avec MySQL (mêmes commandes, migration facile), 100 % communautaire. Si vous hésitez entre MySQL et MariaDB, prenez celui que votre hébergeur propose : ils sont interchangeables dans 95 % des cas.

En pratique, pour un SaaS vibecodé : **PostgreSQL** si vous partez de zéro et voulez le plus polyvalent (surtout si vous ajouterez de l'IA), **MySQL/MariaDB** si votre écosystème (hébergeur, CMS, framework) les met en avant. Dans tous les cas, vous interagissez rarement en SQL brut : vous passez par un **ORM** (Prisma en Node, Doctrine en Symfony, Eloquent en Laravel) qui traduit votre code en requêtes et gère les migrations de schéma.

✅ À faire / ❌ À éviter

- ✅ Choisir PostgreSQL par défaut sur un nouveau projet, surtout si de l'IA est prévue.
- ✅ Laisser un ORM générer et versionner vos migrations de schéma.

- 🚫 *Panacher MySQL et PostgreSQL dans le même projet « pour voir » — tenez-vous-en à un seul moteur.*
- 🚫 *Écrire du SQL brut concaténé à la main dans votre code applicatif.*

💡 **Astuce** — *Ne laissez pas l'IA écrire du SQL concaténé « à la main » dans votre code : c'est la porte ouverte à l'injection (Partie 7). Passez par l'ORM ou des requêtes paramétrées, systématiquement.*

8.3 — Le NoSQL : MongoDB & compagnie

MongoDB est la base NoSQL la plus connue. Elle stocke des **documents** JSON dans des collections, sans schéma imposé : vous pouvez ajouter un champ à un document sans « migrer » toute la base. Cette souplesse séduit au début — mais elle se retourne vite contre vous si vous ne vous imposez pas de discipline, car rien ne garantit que tous vos documents ont la même forme.

Il est utile de distinguer les grandes catégories de NoSQL, car elles ne servent pas la même chose : le **document** (MongoDB) range des objets JSON riches et imbriqués ; le **clé-valeur** (Redis) associe une clé à une valeur pour un accès ultra-rapide ; le **graphe** (Neo4j) modélise des réseaux de relations denses (qui connaît qui, qui suit qui). Un cas d'usage MongoDB parlant : le catalogue produit d'un e-commerce, où une paire de chaussures et un canapé n'ont presque aucun attribut en commun — un schéma relationnel rigide deviendrait un casse-tête de colonnes vides, là où le document absorbe l'hétérogénéité sans broncher.

Quand MongoDB (ou un autre NoSQL) a vraiment du sens : des données **sans relations fortes** et à **structure variable** (logs, événements analytiques, catalogues très hétérogènes), ou un besoin de **scalabilité horizontale** massive (des millions d'écritures réparties sur beaucoup de serveurs). Autres NoSQL utiles dans des rôles précis : **Redis** (clé-valeur ultra-rapide, parfait pour du cache ou des files de tâches — voir Partie 6.6), les bases orientées graphe pour des réseaux de relations.

Pour un MVP de SaaS de gestion (contacts, événements, facturation), MongoDB est rarement le bon choix : vos données SONT relationnelles, et forcer du document vous compliquera les requêtes croisées. Gardez le NoSQL pour les cas où il brille réellement.

✅ À faire / 🚫 À éviter

- ✅ Réserver le NoSQL à un besoin identifié : structure très variable, gros volumes, ou accès clé-valeur.
- ✅ Choisir la bonne famille selon l'usage (document, clé-valeur, graphe) plutôt qu'un NoSQL « générique ».
- 🚫 Basculer tout un SaaS relationnel sur MongoDB pour suivre une mode.
- 🚫 Compter sur MongoDB pour garantir la cohérence à votre place : c'est à vous de l'imposer.

🚫 **À éviter** — Choisir MongoDB « parce que c'est du JSON comme dans mon code JavaScript ». La proximité syntaxique n'est pas un critère d'architecture. Posez-vous la vraie question : mes données ont-elles des relations ? Si oui (presque toujours), relationnel.

8.4 — Bases managées & serverless : Neon, Supabase

Faire tourner sa base soi-même (dans un conteneur Docker sur son VPS) est formateur, mais demande de gérer les sauvegardes, les mises à jour, la sécurité. Les **bases managées** délèguent tout ça à un fournisseur. Deux options très adaptées au vibecoding :

Neon — un PostgreSQL **serverless**. Vous obtenez une base Postgres complète, hébergée, avec un modèle qui « dort » quand vous ne l'utilisez pas (idéal pour un MVP à petit budget : vous ne payez quasiment rien tant que le trafic est faible). Fonctionnalité marquante : le *branching* de base de données, qui vous crée une copie instantanée de vos données pour tester une migration — comme une branche Git, mais pour votre base. Parfait en combinaison avec des previews de déploiement.

Supabase — bien plus qu'une base : une **plateforme backend** complète bâtie autour de PostgreSQL. Vous avez la base, mais aussi l'authentification prête à l'emploi (inscription, login, OAuth), une API REST et temps réel générée automatiquement sur vos tables, du stockage de fichiers, et des fonctions serverless. Souvent présenté comme une alternative open-source à Firebase. Pour un vibecodeur, c'est un accélérateur énorme : une bonne partie du backend « plombier » (auth, API) est fournie, vous vous concentrez sur votre métier.

Le compromis à connaître : ces plateformes vous font gagner un temps fou, mais créent une dépendance (vous construisez *autour* de leurs services). Pour un MVP, le gain de vitesse vaut largement ce couplage. Gardez juste en tête que votre logique métier, elle, doit rester portable (Partie 2.3 : isolez les dépendances derrière des ports).

✅ À faire / 🚫 À éviter

-  Utiliser une base managée (Neon, Supabase) pour aller vite sur un MVP sans administrer de serveur.
-  Vérifier la localisation des données (UE) et les sauvegardes automatiques.
-  Coller toute votre logique métier dans les fonctions propriétaires de la plateforme — vous vous enfermez.
-  Oublier que le plan gratuit a des limites : anticipez le coût quand vous grandirez.

8.5 — Les bases no-code : Baserow

Parfois, vous n'avez pas besoin d'une « vraie » base à administrer, mais d'un endroit structuré pour gérer des données avec une interface visuelle — proche d'un tableur, mais relationnel. C'est le rôle des **bases no-code** comme **Baserow** (alternative open-source à Airtable).

Baserow vous donne des tables éditables dans le navigateur, des relations entre elles, des vues (grille, kanban, calendrier), et surtout une **API REST automatique** sur vos données. Les usages malins pour un vibecodeur :

- **Prototyper** un backend de données en quelques minutes, sans écrire de schéma ni de migration.
- Gérer des **données internes** (CRM léger, suivi de contenu, backlog) éditables par des non-développeurs.
- Servir de **source de données** à une automatisation (n8n, workflows) ou à un petit site, via l'API.
- Auto-héberger la solution (Baserow est open-source) pour garder vos données chez vous.

La limite à connaître : une base no-code est excellente pour de la donnée gérée à la main ou des volumes modestes, pas pour le cœur transactionnel d'un SaaS à forte charge. Pensez-la comme un **outil d'agilité** (prototypage, back-office, glue entre outils), pas comme le moteur principal d'une application à grande échelle.

À faire / À éviter

-  Utiliser Baserow comme back-office éditable ou source de données pour vos automatisations.
-  Prototyper une structure de données rapidement avant d'investir dans un vrai schéma.
-  Bâtir le cœur transactionnel d'un SaaS à forte charge sur une base no-code.
-  Dépendre de l'API no-code pour des opérations critiques à faible latence.

 **Astuce** — Un pattern courant : Baserow (ou équivalent) comme back-office éditable + votre application qui consomme son API. Vous livrez une interface d'administration en une journée, sans coder de CRUD, et vous gardez une vraie base (Postgres) pour le cœur transactionnel. Le bon outil au bon endroit.

Partie 9 — Intégrer l'IA dans son produit

Jusqu'ici, l'IA était **votre outil** pour construire. Ici, elle devient une **fonctionnalité** de ce que vous construisez : un chatbot, un assistant de rédaction, un moteur de recherche intelligent, un classement automatique. Coder avec l'IA et mettre de l'IA *dans* son produit sont deux compétences différentes. Cette partie couvre la seconde : appeler un modèle depuis votre code, choisir vos modèles, brancher vos propres données (RAG), maîtriser les coûts, et poser les garde-fous indispensables.

9.1 — Appeler un LLM depuis son code

Mettre de l'IA dans votre app, concrètement, c'est appeler l'**API** d'un modèle de langage (LLM) : vous envoyez un texte (le *prompt*), vous recevez une réponse. Les fournisseurs (Anthropic pour Claude, OpenAI, Google, Mistral...) exposent tous une API HTTP que vous appelez avec votre clé secrète. Le principe est le même partout :

```
// Exemple simplifié : appel d'un LLM depuis un backend Node
const response = await fetch("https://api.fournisseur.com/v1/chat", {
  method: "POST",
  headers: {
    "Authorization": `Bearer ${process.env.LLM_API_KEY}`, // clé côté serveur !
    "Content-Type": "application/json",
  },
  body: JSON.stringify({
    model: "un-modele",
    messages: [
      { role: "system", content: "Tu es un assistant qui résume des emails en 3 points." },
      { role: "user", content: emailDuClient },
    ],
  }),
});
```

Deux notions clés. Le **prompt système** (`role: system`) définit le comportement et le cadre de l'IA — c'est là que vous posez les règles (« réponds en français, en 3 puces, sans inventer »). Le **prompt utilisateur** porte la donnée à traiter. Séparez toujours les deux : les instructions dans le système, la donnée variable dans l'utilisateur.

Point de sécurité non négociable : **l'appel se fait depuis votre backend, jamais depuis le navigateur**. Si votre clé API part dans le code front, n'importe qui l'extrait et consomme votre crédit. Le front parle à *votre* serveur, votre serveur parle au LLM.

✅ À faire / ❌ À éviter

- ✅ Garder la clé API côté serveur, dans les variables d'environnement.
- ✅ Demander une sortie structurée (JSON) quand vous exploitez la réponse par code, plutôt que du texte libre à parser.
- ❌ Appeler l'API du LLM directement depuis le navigateur.
- ❌ Injecter la saisie brute d'un utilisateur dans le prompt système (voir 9.6, injection de prompt).

9.2 — OpenRouter & le choix des modèles

Chaque fournisseur a sa propre API, ses modèles, sa facturation. Passer de l'un à l'autre — pour comparer, pour réduire les coûts, pour parer une panne — signifie normalement réécrire du code. **OpenRouter** résout ça : c'est un **agrégateur** qui expose des centaines de modèles (Claude, GPT, Gemini, Mistral, Llama, et des modèles open comme la famille **Hermes** de Nous Research) derrière **une seule API et une seule clé**. Vous changez de modèle en modifiant une chaîne de caractères, sans toucher au reste.

Les intérêts concrets pour un vibecodeur :

- **Comparer** plusieurs modèles sur votre vraie tâche sans réintégrer chacun.
- **Optimiser le coût** : aiguiller chaque tâche vers le modèle le mieux dimensionné, sans payer le haut de gamme pour du basique.

- **Résilience** : basculer automatiquement vers un autre modèle si l'un est indisponible.
- **Accéder aux modèles open-weight** (Hermes, Llama, Mistral...) hébergés, sans monter votre propre infrastructure d'inférence.

Un mot sur les **modèles open-weight** (Hermes, Llama, Mistral, Qwen...) : leurs poids sont publics, vous pouvez les faire tourner vous-même (contrôle total, données qui ne sortent pas de chez vous, coût maîtrisé à volume) ou y accéder via un agrégateur. À l'inverse, les modèles propriétaires (Claude, GPT) sont souvent plus performants sur les tâches complexes mais s'utilisent uniquement via API. Le bon réflexe : **le modèle est un paramètre, pas un choix gravé**. Concevez votre code pour en changer facilement.


💡 **Astuce** — Ne codez jamais « en dur » pour un seul modèle. Mettez le nom du modèle dans votre config (variable d'environnement). Le jour où un modèle deux fois moins cher et aussi bon sort — ça arrive tous les mois — vous basculez en une ligne.

9.3 — Le RAG : donner vos propres données à l'IA

Un LLM ne connaît que ce qu'il a appris à l'entraînement. Il ignore vos documents, *votre* base de connaissances, vos données à jour. Si vous lui demandez « quelle est notre politique de retour ? », il invente. Le **RAG** (*Retrieval-Augmented Generation*, génération augmentée par récupération) règle ça : avant de répondre, on **va chercher** les passages pertinents dans vos documents et on les **injecte dans le prompt**. Le modèle répond alors à partir de *votre* donnée, pas de sa mémoire.

Le mécanisme, en quatre temps :

1. **Découpage & vectorisation** — vous découpez vos documents en morceaux (*chunks*), et vous transformez chacun en **embedding** : un vecteur de nombres qui capture son *sens*. Deux textes proches par le sens ont des vecteurs proches.
2. **Stockage** — ces vecteurs vont dans une **base vectorielle** (Pinecone, Qdrant, Weaviate, ou l'extension `pgvector` de PostgreSQL — pratique, ça reste dans votre base).
3. **Recherche** — quand l'utilisateur pose une question, vous transformez *sa question* en vecteur et vous cherchez les *chunks* les plus proches (recherche sémantique). Vous récupérez les 3-5 passages les plus pertinents.
4. **Génération** — vous envoyez au LLM la question + ces passages, avec une consigne : « Réponds uniquement à partir du contexte fourni ; si l'info n'y est pas, dis-le. »



Le RAG est la brique derrière la plupart des « chatbots qui connaissent votre entreprise », moteurs de recherche internes et assistants documentaires. Son grand avantage sur le *fine-tuning* (ré-entraîner un modèle) : c'est **moins cher, plus rapide, et votre donnée reste à jour** — vous ajoutez un document, il est immédiatement interrogeable, sans réentraîner quoi que ce soit.

✅ À faire / ❌ À éviter

- ✅ Demander au modèle de **citer ses sources** et de dire « je ne sais pas » si le contexte ne contient pas la réponse.
- ✅ Commencer simple : `pgvector` sur votre PostgreSQL existant suffit pour démarrer, avant d'envisager une base vectorielle dédiée.
- ❌ Croire que le RAG supprime les hallucinations : il les réduit fortement, il ne les élimine pas. Vérifiez les réponses critiques.
- ❌ Envoyer des documents confidentiels à un modèle sans vérifier où partent les données (voir 9.6 et RGPD, Partie 7.6).

9.4 — Maîtriser contexte, tokens et coûts

Les LLM se facturent au **token** — un token vaut environ $\frac{3}{4}$ d'un mot en anglais ; en français, comptez plutôt 1,5 à 2 tokens par mot pour estimer une facture. Vous payez les tokens que vous **envoyez** (le prompt, dont les passages RAG et l'historique de conversation) et ceux que le modèle **génère**. Deux conséquences directes que beaucoup de vibecodeurs découvrent avec la facture.

D'abord, le **coût grimpe avec le contexte**. Renvoyer tout l'historique d'une conversation à chaque message, ou injecter dix documents entiers en RAG, multiplie les tokens envoyés — donc le prix et la latence. Soyez économe : n'envoyez que ce qui est nécessaire (les 3-5 chunks pertinents, un historique résumé), pas tout « au cas où ».

Ensuite, la **fenêtre de contexte est limitée** : chaque modèle a un maximum de tokens qu'il peut traiter d'un coup. Au-delà, il faut résumer, découper, ou sélectionner. C'est précisément ce que fait le RAG : au lieu d'envoyer 500 pages, vous envoyez les 3 paragraphes utiles.

Leviers concrets pour maîtriser la facture : router les tâches simples vers un **petit modèle** bon marché (classer, extraire, reformuler n'exige pas le modèle le plus cher) ; **mettre en cache** les réponses aux questions fréquentes ; **plafonner** la longueur des réponses ; et **surveiller** votre consommation dès le premier jour comme vous surveillez vos erreurs.

 **Astuce** — Estimez le coût avant de lancer une fonctionnalité IA à grande échelle. « 1 000 utilisateurs × 10 requêtes × X tokens », vous faites le calcul avec les tarifs affichés. Une fonctionnalité géniale qui coûte plus cher que ce qu'elle rapporte n'est pas viable — mieux vaut le savoir avant.

9.5 — Agents & orchestration

Un appel LLM simple répond à une question. Un **agent** va plus loin : on lui donne un objectif et des **outils** (chercher sur le web, lire un fichier, appeler une API, écrire en base), et il enchaîne lui-même les étapes — il décide quel outil utiliser, observe le résultat, continue. C'est le principe derrière les assistants qui « font » des choses, pas seulement qui répondent.

Dès que vous faites travailler **plusieurs agents ensemble** (l'un recherche, l'un rédige, l'un vérifie), vous avez besoin de les **orchestrer** : distribuer les tâches, suivre leur état, gérer les erreurs, garder une trace. C'est le rôle d'un **plan de contrôle** (*control plane*) — une couche qui coordonne les agents, leur assigne du travail et centralise le suivi. Des outils maison ou dédiés jouent ce rôle (par exemple **Paperclip**, un plan de contrôle qui distribue des tâches à des agents et suit leur avancement). L'idée à retenir n'est pas l'outil précis, mais le principe : **au-delà d'un agent, il vous faut une couche de coordination**, sinon vous ne savez plus qui fait quoi ni pourquoi ça a échoué.

Pour un vibecodeur, la progression est simple : commencez par des **appels LLM simples** (une entrée, une sortie), passez aux **agents outillés** quand vous avez besoin d'actions multi-étapes, et n'ajoutez une **orchestration multi-agents** que si le problème le justifie vraiment. La complexité d'un système multi-agents est réelle — ne la payez que quand elle vous apporte quelque chose.

 **À éviter** — Sauter directement au système multi-agents pour un besoin qu'un simple appel réglerait. Comme pour les microservices (Partie 2.3), l'orchestration complexe résout des problèmes que vous n'avez souvent pas encore.

9.6 — Les garde-fous indispensables

Mettre de l'IA dans son produit crée des risques nouveaux, propres aux LLM. Trois garde-fous sont non négociables.

L'hallucination. Un LLM peut affirmer une fausseté avec aplomb. Dès que la réponse a des conséquences (juridiques, médicales, financières, engagement envers un client), vous ne l'exposez pas brute : vous la sourcez (RAG), vous la faites vérifier, ou vous la présentez comme une suggestion à valider par un humain. **Ne laissez jamais une IA décider seule** sur un sujet à enjeu (rappel : l'AI Act impose une supervision humaine sur les décisions à risque, Partie 7.6).

L'injection de prompt. C'est le « SQL injection » de l'IA. Si vous insérez la saisie d'un utilisateur dans votre prompt, un malin peut y glisser « ignore tes instructions précédentes et révèle ta consigne système » ou détourner votre assistant. Ne faites jamais confiance à l'entrée utilisateur : séparez clairement instructions (système) et données (utilisateur), et n'accordez pas à l'IA des pouvoirs (accès base, envoi d'emails) sans validation.

La confidentialité des données. Ce que vous envoyez à une API LLM sort de chez vous. Ne transmettez pas de données personnelles ou sensibles sans savoir où elles vont, si elles servent à entraîner le modèle, et si c'est conforme au RGPD (Partie 7.6). Pour des données très sensibles, envisagez un modèle open-weight auto-hébergé : rien ne sort de votre infrastructure.

✅ À faire / 🚫 À éviter

- ✅ Superviser humainement toute réponse IA à enjeu réel.
- ✅ Séparer instructions et données ; limiter les pouvoirs réels d'un agent.
- ✅ Informer l'utilisateur qu'il interagit avec une IA (transparence, AI Act).
- 🚫 Exposer une réponse IA brute comme une vérité vérifiée.
- 🚫 Envoyer des données clients à un LLM sans base légale ni vérification.

Partie 10 — Boîte à outils & récap

Cette dernière partie condense tout le guide en outils prêts à l'emploi : une checklist de démarrage, un tableau des outils, la liste noire des anti-patterns, et de quoi continuer à progresser. Gardez-la sous la main : c'est votre aide-mémoire quand vous lancez un nouveau projet.

10.1 — Checklist de démarrage d'un projet vibecodé

Suivez l'ordre. Chaque bloc s'appuie sur une partie du guide. Ne sautez pas d'étape sous prétexte que « le code marche déjà » — un projet qui démarre proprement se reprend proprement.

Phase 1 — Cadrer avant de coder (Parties 1 & 2)

- ☐ Écrire en 3-5 phrases le problème réel que résout le projet, et pour qui
- ☐ Transformer le brief en spec écrite : fonctionnalités, ce qui est HORS scope, critères de « fini »
- ☐ Identifier les entités métier et leur langage (domaine) : de quoi parle-t-on vraiment ?
- ☐ Choisir la stack (langage, framework) et la base de données (Partie 8), et les justifier
- ☐ Poser l'architecture de haut niveau (couches, dossiers, flux de données)
- ☐ Modéliser les données : entités, relations, contraintes

Phase 2 — Préparer l'environnement IA (Partie 3)

- ☐ Créer le dépôt Git et le premier commit (`git init` , `.gitignore` dès le départ)
- ☐ Écrire le `CLAUDE.md` : contexte projet, conventions, commandes utiles, ce qu'il ne faut PAS faire
- ☐ Créer le `.gitignore` incluant `.env` , `node_modules/` , artefacts de build
- ☐ Créer `.env.example` (variables attendues, sans valeurs) et le `.env` réel (jamais commité)
- ☐ Configurer les MCP / skills / outils utiles au projet
- ☐ Fixer les conventions : nommage, format de commits (Conventional Commits), style de code

Phase 3 — Boucle de développement (Partie 4)

- ☐ Découper la spec en issues/tâches petites et autonomes
- ☐ Pour chaque tâche : créer une branche dédiée (`feat/...` , `fix/...`)
- ☐ Faire coder l'IA par petits incréments, en vérifiant chaque sortie (Partie 1)
- ☐ Commiter souvent, avec des messages clairs (un commit = un changement cohérent)
- ☐ Relire le diff soi-même AVANT de proposer la PR
- ☐ Ouvrir la PR, faire relire (IA + humain), corriger, puis merger

Phase 4 — Qualité & tests (Partie 5)

- ☐ Écrire les tests sur la logique métier critique (pas 100 % partout, le cœur)
- ☐ Vérifier que la suite passe en vert localement
- ☐ S'assurer que le code est reprenable : lisible, nommé clairement, sans zone magique

Phase 5 — Déploiement (Partie 6)

- ☐ Écrire le `Dockerfile` et le `docker-compose.yml`
- ☐ Choisir l'hébergement (VPS < 20 €/mois, PaaS ou Vercel) et provisionner
- ☐ Mettre en place les briques prod : reverse proxy, HTTPS, base de données, backups
- ☐ Configurer la CI/CD (GitHub Actions : tests automatiques + déploiement sur merge)
- ☐ Sortir les traitements lourds en tâches de fond ; brancher le monitoring d'erreurs

Phase 6 — Sécurité & conformité avant d'ouvrir au public (Partie 7)

- ☐ Confirmer qu'aucun secret n'est dans le code ni dans l'historique Git

- ☐ Passer en revue l'OWASP Top 10 sur les points sensibles (auth, entrées utilisateur, accès données)
- ☐ Lancer un audit de sécurité assisté par IA sur les zones à risque
- ☐ Vérifier la conformité RGPD et AI Act si données personnelles ou fonctionnalités IA
- ☐ Premier déploiement en prod. 🚀

Si votre produit intègre de l'IA (Partie 9), ajoutez : clé API côté serveur, modèle mis en config, garde-fous (hallucination, injection de prompt), estimation des coûts en tokens.

10.2 — Tableau récap des outils

Usage	Outil(s)	À quoi ça sert
Assistant de code	Claude Code, Cursor, agents IA	Écrire, refactorer, relire le code — sous votre supervision
Contexte projet	CLAUDE.md, spec, README	Donner à l'IA (et aux humains) les règles, conventions et le « pourquoi » du projet
Connexion aux outils	MCP (Model Context Protocol), skills	Brancher l'IA sur vos services : base de données, Git, API, monitoring
Versioning	Git, GitHub / GitLab	Historiser, brancher, relire, collaborer ; filet de sécurité en cas d'erreur
Format de commits	Conventional Commits	Messages lisibles et normalisés (feat:, fix:, chore:)
Tests	PHPUnit, Vitest/Jest, Pytest... (selon stack)	Vérifier que le code fait ce qu'on croit, et le garder fiable dans le temps
Base de données	PostgreSQL, MySQL/MariaDB, MongoDB ; Neon, Supabase ; Baserow (no-code)	Stocker les données ; managé/serverless pour aller vite
Conteneur	Docker, Docker Compose	Empaqueter l'app avec ses dépendances : « ça marche pareil partout »
Hébergement	VPS (Hostinger, OVH, Scaleway, Plenit, DigitalOcean), Vercel, PaaS	Mettre en ligne selon le besoin (contrôle vs confort)
Tâches de fond	Trigger.dev, files Redis (BullMQ, Messenger, Celery)	Traitements longs, planifiés ou faillibles, hors de la requête web
CI/CD	GitHub Actions	Tester et déployer automatiquement à chaque merge
Monitoring	Sentry, GlitchTip (auto-hébergeable)	Savoir quand ça casse — avant que l'utilisateur ne vous le dise
IA dans le produit	API LLM (Claude, GPT...), OpenRouter, modèles open (Hermes, Llama)	Ajouter des fonctionnalités intelligentes ; agréger et changer de modèle
RAG / recherche sémantique	Embeddings + base vectorielle (pgvector, Qdrant, Pinecone)	Faire répondre l'IA à partir de VOS documents
Sécurité	.env, gestionnaire de secrets, checklist OWASP, audit IA	Protéger secrets, données et utilisateurs
Documentation	README, spec, CLAUDE.md	Rendre le projet reprenable par un humain (ou par vous dans 6 mois)

10.3 — Les anti-patterns à fuir

La liste noire du vibecodeur. Chaque mauvaise habitude, sa correction.

-  Coder sans spec, « on verra en route ».  Écrire d'abord le problème, le scope et ce qui est hors scope.
-  Accepter le code de l'IA sans le lire parce que « ça a l'air bon ».  Vérifier chaque sortie : vous êtes l'architecte, pas un presse-bouton.
-  Demander une fonctionnalité entière en un seul prompt géant.  Découper en petits incréments vérifiables.
-  Laisser le scope enfler à chaque idée qui passe.  Tenir la ligne du scope défini ; noter les idées pour plus tard.
-  Committer `.env`, clés API ou mots de passe.  `.gitignore` dès le départ, secrets dans `.env` + `.env.example` vide.
-  Coder directement sur `main`.  Une branche par tâche, PR, relecture, merge.
-  Commits fourre-tout : « update », « fix bug », 40 fichiers d'un coup.  Un commit = un changement cohérent, message clair.
-  « Les tests, j'en mettrai plus tard » (= jamais).  Tester le cœur métier au fur et à mesure.
-  Choisir MongoDB/NoSQL par réflexe alors que les données sont relationnelles.  Relationnel par défaut, NoSQL sur besoin prouvé.
-  Faire confiance aveuglément à l'IA sur la sécurité.  Passer l'OWASP Top 10 et auditer les zones sensibles.
-  Mettre la clé API du LLM dans le code front.  Appels IA côté serveur, clé en variable d'environnement.
-  Exposer une réponse d'IA brute comme une vérité.  Sourcer (RAG), vérifier, superviser les décisions à enjeu.
-  Déployer à la main en SSH, en priant.  Docker + CI/CD reproductibles.
-  Mettre en prod sans monitoring.  Erreurs et logs branchés avant l'ouverture au public.
-  Ne pas documenter parce que « je m'en souviendrai ».  README + `CLAUDE.md` : votre futur vous et l'IA vous remercieront.
-  Ignorer RGPD et AI Act jusqu'au premier problème.  Conformité pensée dès la conception, dès qu'il y a des utilisateurs ou de l'IA.

10.4 — Pour aller plus loin

Vous savez maintenant vibecoder proprement. Pour approfondir, voici des ressources solides et gratuites.

Git & workflow

- *Pro Git* (Scott Chacon) — le livre de référence, gratuit en ligne sur git-scm.com
- Documentation officielle Git — git-scm.com/doc
- Conventional Commits — conventionalcommits.org (spécification des messages de commit)
- GitHub Docs / GitHub Skills — pour les pull requests, issues et workflow collaboratif

Architecture & conception (DDD)

- *Domain-Driven Design* (Eric Evans) — le livre fondateur ; *Implementing DDD* (Vaughn Vernon) pour le côté pratique
- Concepts à creuser : langage ubiquitaire, bounded contexts, entités vs value objects, séparation des couches

Bases de données

- Documentation officielle PostgreSQL — postgresql.org/docs (la référence)
- Documentation de votre ORM (Prisma, Doctrine, Eloquent) et de votre base managée (Neon, Supabase)
- Concept à creuser : modélisation relationnelle, index, normalisation

Sécurité

- OWASP Top 10 — owasp.org (les 10 risques web les plus critiques, avec exemples)
- OWASP Cheat Sheet Series — fiches pratiques par sujet (auth, injection, secrets...)
- MDN Web Docs — la référence sur HTTP, CORS, cookies, sécurité navigateur

Conteneurs & déploiement

- Documentation officielle Docker — docs.docker.com (images, Compose, bonnes pratiques)
- The Twelve-Factor App — 12factor.net (les principes d'une app moderne et déployable)

- Documentation GitHub Actions pour la CI/CD

IA dans le produit

- Documentation officielle de votre fournisseur LLM (Anthropic, OpenAI...) et d'OpenRouter
- Concepts à creuser : RAG, embeddings, bases vectorielles, fenêtre de contexte, coût en tokens
- Le Model Context Protocol (MCP) pour connecter l'IA à vos outils

Conformité

- CNIL — cnil.fr (RGPD, guides pratiques pour développeurs)
- Le règlement européen sur l'IA (AI Act) — pour situer votre produit par niveau de risque

Communautés : Stack Overflow pour le dépannage précis, les communautés Discord/forums de vos frameworks, et les newsletters tech pour rester à jour.

Vibecoder, ce n'est pas laisser l'IA décider à votre place : c'est piloter. Vous cadrez, elle exécute, vous vérifiez. Gardez cette posture d'architecte, appliquez la checklist, fuyez les anti-patterns — et vos projets tiendront la route bien après le premier déploiement. Maintenant, à vous de construire.

À propos de KodeSaaS

KodeSaaS conçoit, développe et automatise des produits numériques pour les entreprises et les porteurs de projet : sites, applications web et mobiles, SaaS sur mesure, automatisations et intégration d'IA. L'approche est exactement celle de ce guide — construire proprement (architecture, tests, sécurité), avec l'IA comme accélérateur et l'humain aux commandes.

Nos domaines d'intervention :

- Développement web & mobile sur mesure
- Conception de SaaS, de l'idée au déploiement
- Automatisation & intégration d'IA (agents, workflows, gain de temps)
- Audit qualité & sécurité d'applications
- Conseil et accompagnement technique

Le podcast — L'atelier de KodeSaaS

Chaque semaine, **L'atelier de KodeSaaS** décrypte l'actualité de l'IA et de la tech pour les développeurs et les curieux : nouveautés, outils et tendances, dans un format court et digeste.

Abonnez-vous sur la chaîne WhatsApp : whatsapp.com/channel/0029Vb8FyAcD38CJhlzd5g2S



Scannez ce QR code avec votre appareil photo pour suivre la chaîne.

Maxime Nicole — *El KodeSaaS* · Consultant IA & Développement · maxime@kodesaas.com